

UNIVERSIDAD DE MÁLAGA



E.T.S. INGENIERÍA INFORMÁTICA
UNIVERSIDAD DE MÁLAGA

Graduado en Ingeniería Informática

Optimización global de modelos de Media-Varianza-Sostenibilidad multiagencia para gestión de carteras

Global optimization of multi-agency Mean-Variance-Sustainability models for portfolio management

Realizado por
José Antonio Luque Salguero

Tutorizado por
Francisco de Asís Fernández Navarro

Departamento
Lenguajes y ciencias de la computación

MÁLAGA, septiembre de 2024

UNIVERSIDAD DE MÁLAGA

E.T.S. INGENIERÍA INFORMÁTICA
UNIVERSIDAD DE MÁLAGA

ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA INFORMÁTICA
GRADUADO EN INGENIERÍA INFORMÁTICA

Optimización global de modelos de Media-Varianza-Sostenibilidad multiagencia para gestión de carteras

Global optimization of multi-agency Mean-Variance-Sustainability models for portfolio management

Realizado por
José Antonio Luque Salguero

Tutorizado por
Francisco de Asís Fernández Navarro

Departamento
Lenguajes y ciencias de la computación

UNIVERSIDAD DE MÁLAGA
MÁLAGA, SEPTIEMBRE DE 2024

Fecha defensa: septiembre de 2024

Abstract

Portfolio management is a field of great interest for investors and asset managers, who seek to maximize returns while minimizing associated risk. In recent years, there has been a growing interest in integrating sustainability criteria into investment decision-making, reflecting an increasing concern for the social and environmental impacts of economic activities.

While previous approaches to portfolio optimization consider one or two of the mentioned objectives, the key contributions of this thesis lie in the integration of all three objectives into a single non-convex quadratic model, as well as the application of population-based algorithms for its resolution. Additionally, innovative strategies will be explored to address the problem, and the performance of the proposed approach will be empirically evaluated in comparison with benchmark methods from the literature.

Keywords: portfolio optimization, population-based algorithms, ESG ratings

Resumen

La gestión de carteras es un campo de gran interés para inversores y gestores de activos, quienes buscan maximizar los rendimientos mientras minimizan el riesgo asociado. En los últimos años, ha surgido un interés creciente en la integración de criterios de sostenibilidad en la toma de decisiones de inversión, lo que refleja una preocupación creciente por los impactos sociales y ambientales de las actividades económicas.

Si bien existen enfoques previos para la optimización de carteras que consideran uno o dos de los objetivos mencionados, las contribuciones clave de este TFG radican en la integración de los tres objetivos en un único modelo cuadrático no convexo, así como en la aplicación de algoritmos basados en poblaciones para su resolución. Además, se explorarán estrategias innovadoras para abordar el problema y se evaluará empíricamente el desempeño del enfoque propuesto en comparación con métodos de referencia en la literatura.

Palabras clave: gestión de carteras, algoritmos basados en poblaciones, ESG

Índice

1. Introducción **7**

1.1. Motivación . . . 7

1.2. Objetivos . . . 8

1.3. Estructura del documento . . . 9

1.4. Tecnologías usadas . . . 10

1.4.1. *NumPy* . . . 10

1.4.2. *Pandas* . . . 10

1.4.3. *Matplotlib* . . . 10

1.4.4. DEAP . . . 11

1.4.5. *cvxpy* . . . 11

2. Desarrollo teórico **13**

2.1. Problemas multiobjetivo . . . 13

2.1.1. Programación cuadrática . . . 15

2.2. Modelo de Media-Varianza de Markowitz . . . 15

2.3. Calificación ESG . . . 17

2.4. Modelo Media-Varianza-ESG (MV(ESG)) . . . 18

2.5. Discrepancia entre agencias de calificación de criterios ESG . . . 19

2.6. Modelo de Media-Varianza-ESG multiagencia . . . 20

2.6.1. Características del modelo. . . . 23

2.6.2. Limitaciones del modelo . . . 24

2.7. Modelo de Media-Varianza-ESG multiagencia de dos etapas . . . 24

2.7.1. Primera etapa . . . 25

2.7.2. Características del modelo . . . 26

2.7.3. Segunda etapa . . . 27

2.7.4. Solución del problema . . . 27

3. Algoritmos basados en poblaciones **29**

3.1. Covariance Matrix Adaptation Evolution Strategy (CMA-ES) 31
3.1.1. Principales parámetros 33
3.1.2. Flujo algoritmico 34
3.2. Non-dominated sorting genetic algorithm (NSGA-II) 35
3.2.1. Principales parámetros 37
3.2.2. Flujo algoritmico 39
3.3. Particle Swarm Optimization (PSO) 39
3.3.1. Principales parámetros 42
3.3.2. Flujo algorítmico 42

4. Desarrollo experimental **45**
4.1. Conjunto de datos 45
4.2. Frontera de Pareto 46
4.3. Implementación del modelo multiagencia en dos etapas 49
4.4. Comparativa del modelo multiagencia en dos etapas 52
4.4.1. Carteras de inversión a comparar 53
4.4.2. Comparativa 56

5. Conclusiones y Líneas Futuras **59**
5.1. Conclusiones 59
5.2. Líneas Futuras 59

Apéndice A. Manual de Instalación **65**

1 Introducción

1.1. Motivación

La gestión de carteras es un campo de gran interés para inversores y gestores de activos, quienes buscan maximizar los rendimientos mientras minimizan el riesgo. El enfoque por excelencia para equilibrar y optimizar estos dos objetivos es el modelo de Media-Varianza (MV) de Markowitz [29, 12]. Este modelo se centra en maximizar el retorno esperado de una cartera (la media), mientras se minimiza el riesgo, medido a través de la varianza o volatilidad de los retornos. Se le llama "media-varianza" porque emplea la media como indicador de rentabilidad y la varianza como medida del riesgo, proporcionando así un marco cuantitativo para gestionar el equilibrio entre ambos [30].

En los últimos años, el interés por las inversiones sostenibles ha crecido significativamente en la literatura académica y en la práctica financiera, reflejando una preocupación cada vez mayor por los impactos sociales y ambientales de las actividades económicas. Este cambio de enfoque ha impulsado la integración de criterios de sostenibilidad en la toma de decisiones de inversión, con el objetivo de alinearse con valores éticos y lograr un desarrollo más equilibrado a largo plazo [32]. Para medir la sostenibilidad, comúnmente se utilizan las calificaciones ESG (siglas en inglés de *"Environmental, Social, and Governance"*), que proporcionan una evaluación integral del desempeño ambiental, social y de gobierno corporativo de las empresas. Sin embargo, estas calificaciones varían considerablemente entre las distintas agencias que las emiten, lo que plantea un desafío metodológico a la hora de integrarlas en modelos financieros [3].

En la literatura reciente, existen estudios que incorporan el criterio ESG como un tercer objetivo en la optimización de carteras, junto a los tradicionales objetivos de rentabilidad y riesgo [39]. Sin embargo, la mayoría de estos enfoques se basa en los ratings ESG de una sola agen-

cia de calificación, lo cual puede limitar la diversidad y la fiabilidad de las evaluaciones [14]. Según diversas investigaciones, las calificaciones ESG de diferentes agencias pueden divergir significativamente debido a metodologías y enfoques distintos, lo que subraya la importancia de considerar múltiples fuentes de información.

Este Trabajo de Fin de Grado (TFG) propone un enfoque innovador al introducir un modelo multiagencia de Media-Varianza-ESG (MV(ESG)), que integra el análisis de varias agencias de calificación ESG para obtener una visión más robusta y completa de la sostenibilidad en las carteras de inversión. El objetivo es no solo optimizar la rentabilidad y minimizar el riesgo, sino también incorporar de manera efectiva un tercer objetivo de sostenibilidad, abordando las inconsistencias entre las distintas agencias. Este modelo ofrece una mejora significativa frente a los enfoques previos al tener en cuenta la diversidad de criterios ESG y ofrecer una optimización más precisa y alineada con los estándares de sostenibilidad actuales.

Otro punto importante de este trabajo será la aplicación de modelos basados en poblaciones para la resolución del problema de optimización, dado que las características del problema lo hacen intratable mediante los métodos tradicionales [7]. En particular, el problema planteado en este TFG es de naturaleza no convexa, lo que significa que puede tener múltiples óptimos locales, lo cual dificulta que técnicas convencionales, como los métodos de gradiente, puedan encontrar la solución óptima global. Por esta razón, proponemos el uso de enfoques basados en poblaciones, que permiten explorar simultáneamente diversas soluciones candidatas en el espacio de búsqueda.

1.2. Objetivos

El objetivo del TFG es definir un modelo que permita incorporar los tres objetivos del problema de gestión de carteras con enfoque sostenible (beneficios, riesgo, sostenibilidad) teniendo en cuenta la variabilidad de calificaciones entre las distintas agencias de evaluación ambiental. Se comenzará explicando el modelo básico del que se partirá, el modelo de Media-Varianza de Markowitz [29] y los problemas multiobjetivo en general y como extenderlo para conseguir incorporar tanto el objetivo de sostenibilidad como las diferentes calificaciones de evaluación ambiental de las distintas agencias calificadoras. Posteriormente realizaremos un estudio del tipo de problema de optimización que se nos plantea y justificaremos el uso de algoritmos basados en poblaciones [14] para su resolución para proseguir con la implemen-

tación del modelo en una selección de algoritmos de este tipo entre los que podemos poner de ejemplo: *Coral Reef Optimization* (CRO) [35], *Particle Swarm Optimization* (PSO) [33], etc. A continuación realizaremos un análisis del rendimiento de dicho modelo en sus distintas implementaciones con otras estrategias de referencia en la literatura como pueden ser *naive diversification* o *single-asset* lo que nos permitirá contextualizar dichos resultados [31]. Finalmente recopilaremos las conclusiones de dichos resultados y posibles líneas de investigación futuras.

1.3. Estructura del documento

Este documento está organizado en cinco capítulos principales, además de un apéndice final, que se describen a continuación:

- **Capítulo 1: Introducción.** En este capítulo se presentan la motivación del trabajo, los objetivos propuestos y las tecnologías utilizadas para desarrollar el modelo. Se expone la relevancia de integrar criterios de sostenibilidad en la optimización de carteras de inversión.

- **Capítulo 2: Desarrollo teórico.** Se aborda el marco teórico del trabajo, comenzando con una descripción de los problemas multiobjetivo y el modelo de Media-Varianza de Markowitz. Se introduce el concepto de calificación ESG y se detalla el modelo de Media-Varianza-ESG propuesto, incluyendo una versión multiagencia para abordar la discrepancia entre distintas agencias de calificación.

- **Capítulo 3: Algoritmos evolutivos.** Este capítulo explora los algoritmos evolutivos utilizados para la optimización del modelo, CMA-ES, NSGA-II, y PSO. Se describen sus principales parámetros y el flujo algorítmico de cada uno.

- **Capítulo 4: Desarrollo experimental.** Se presenta la implementación del modelo propuesto, detallando el conjunto de datos utilizado, la generación de la frontera de Pareto y una comparativa experimental entre distintas carteras de inversión basadas en el modelo multiagencia de dos etapas.

- **Capítulo 5: Conclusiones y líneas futuras.** Se exponen las principales conclusiones

obtenidas a partir del desarrollo experimental y se proponen posibles líneas de investigación futuras.

- **Apéndice A: Manual de instalación.** Se incluye un apéndice con un manual que detalla los pasos necesarios para la instalación de las tecnologías utilizadas en el desarrollo del modelo.

1.4. Tecnologías usadas

1.4.1. *NumPy*

NumPy es una biblioteca fundamental de *Python* para el cálculo numérico y científico, ampliamente utilizada por su capacidad de manejar arreglos y matrices multidimensionales de manera eficiente. Proporciona un extenso conjunto de funciones matemáticas y estadísticas que permiten realizar operaciones complejas sobre grandes volúmenes de datos de forma rápida y con un uso optimizado de la memoria.

1.4.2. *Pandas*

Pandas es una biblioteca de *Python* diseñada para la manipulación y análisis de datos, ofreciendo estructuras como series y *dataframes* que facilitan la limpieza, transformación y exploración de información. Es ideal para trabajar con grandes volúmenes de datos gracias a su capacidad de importación desde múltiples fuentes y su integración con otras herramientas como *NumPy* y *Matplotlib*, siendo una herramienta fundamental para el análisis de datos y la ciencia de datos.

1.4.3. *Matplotlib*

Matplotlib es una biblioteca de *Python* para crear gráficos y visualizaciones de datos de manera flexible y personalizable. Es ampliamente utilizada en ciencia de datos y análisis, permitiendo generar desde gráficos simples hasta visualizaciones complejas integradas con otras bibliotecas como *NumPy* y Pandas.

1.4.4. DEAP

DEAP ("*Distributed Evolutionary Algorithms in Python*) es una biblioteca de *Python* orientada al desarrollo rápido de algoritmos evolutivos y otras técnicas de optimización metaheurística, como algoritmos genéticos, programación genética y estrategias evolutivas. DEAP proporciona una estructura flexible y modular que permite personalizar fácilmente sus algoritmos, ajustando componentes como la selección, mutación y cruce, entre otros. DEAP facilita la experimentación y la implementación de soluciones complejas para problemas de optimización en diversos campos, como inteligencia artificial, investigación operativa, diseño automatizado y análisis de datos.

1.4.5. *cvxpy*

cvxpy es una biblioteca de *Python* diseñada para la formulación y resolución de problemas de optimización convexa de manera sencilla y expresiva. Desarrollada por investigadores en optimización, *cvxpy* permite a los usuarios modelar una amplia gama de problemas, como programación lineal, cuadrática, cónica y semidefinida, entre otros, utilizando una sintaxis cercana al lenguaje matemático estándar. La biblioteca se encarga automáticamente de transformar el problema en una forma estándar y de seleccionar el algoritmo más adecuado, lo que facilita la resolución eficiente de problemas complejos.

2

Desarrollo teórico

2.1. Problemas multiobjetivo

Los problemas de optimización multiobjetivo son una categoría especial de problemas en la optimización computacional en la que se busca encontrar soluciones que optimicen múltiples criterios u objetivos simultáneamente. En contraste con los problemas de optimización tradicionales, que generalmente tienen un solo objetivo a maximizar o minimizar, los problemas de optimización multiobjetivo involucran la optimización de múltiples funciones objetivo que pueden ser contradictorias o estar en conflicto entre sí.

En estos problemas, no existe una única solución óptima, sino un conjunto de soluciones que conforman lo que se conoce como la frontera de Pareto. Esta frontera de Pareto representa las soluciones que no pueden mejorarse en términos de un objetivo sin empeorar al menos uno de los otros objetivos. En otras palabras, ninguna solución en la frontera de Pareto es dominada por otra en términos de todos los objetivos. En este sentido, la resolución de problemas de optimización multiobjetivo implica encontrar soluciones que sean óptimas en el sentido de Pareto.

La aplicación de problemas de optimización multiobjetivo es amplia y se encuentra en numerosos campos, incluyendo ingeniería, economía, planificación urbana, diseño de productos y logística, entre otros. En estos contextos, es común tener múltiples criterios u objetivos que deben ser considerados simultáneamente al tomar decisiones, lo que hace que los problemas de optimización multiobjetivo sean fundamentales para encontrar soluciones óptimas y equilibradas.

A continuación definiremos formalmente estos conceptos, lo haremos sin pérdida de generalidad para el caso de minimización de todos los objetivos.

Definición 1 (Problema multiobjetivo) *Un problema de optimización multiobjetivo con* n

objetivos se puede formular como sigue:

$$\text{mín } \mathbf{F}(\mathbf{x}) = min\ [F_1(\mathbf{x}), F_2(\mathbf{x}), ..., F_n(\mathbf{x})] \tag{1}$$

$$\begin{aligned} \textit{s.a.} \quad & g_q(\mathbf{x}) \leq 0 \quad (1 \leq q \leq r), \\ & h_k(\mathbf{x}) = 0 \quad (1 \leq k \leq m) \\ & l \leq x_i \leq u \quad (1 \leq i \leq L) \end{aligned} \tag{2}$$

donde $\mathbf{x} = (x_1, ..., x_p)^T$ *es el vector de variables independientes,* $F_j(\mathbf{x})\ \ j = 1, ..., n$ *son los n objetivos,* $g_q(\mathbf{x})$ *son r restricciones de desigualdad,* $h_k(\mathbf{x})$ *son m restricciones de igualdad y finalmente l y u son cota superior e inferior respectivamente de los valores que pueden tomar las componentes de* $\mathbf{x}$*. Las restricciones 2 definen un conjunto que llamaremos espacio de búsqueda D.*

Definición 2 (Solución dominada) *Sean* $\mathbf{x}_1$ *y* $\mathbf{x}_2$ *soluciones factibles de un problema de optimización multiobjetivo, es decir, que satisfacen las restricciones del problema. Entonces decimos que la solución* $\mathbf{x}_1$ *domina a* $\mathbf{x}_2$*, denotado por* $\mathbf{x}_2 \prec \mathbf{x}_1$ *si y solo si*

$$\begin{aligned} F_i(\mathbf{x}_2) \leq F_i(\mathbf{x}_1), \qquad & \forall i \in \{1, ..., n\} \\ F_j(\mathbf{x}_2) < F_j(\mathbf{x}_1), \qquad & \exists j \in \{1, ..., n\} \end{aligned} \tag{3}$$

Definición 3 (Conjunto óptimo de Pareto) *El conjunto óptimo de Pareto,* $\mathbf{x}_p$*, se encuentra conformado por todas aquellas soluciones del espacio de búsqueda, D, tales que no están dominadas por ninguna otra.*

$$\mathbf{x}_p = \{\mathbf{x} \in D \mid \nexists \overline{\mathbf{x}} \in D\ :\ \mathbf{x} \prec \overline{\mathbf{x}}\} \tag{4}$$

Definición 4 (Frontera de Pareto) *La frontera de Pareto o frontera no dominada es la gráfica de la función objetivo* $\mathbf{F}$ *en los vectores del conjunto óptimo de Pareto* $\mathbf{x}_p$*, es decir* $\mathbf{F}(\mathbf{x}_p)$*.*

2.1.1. Programación cuadrática

En el caso de que la función objetivo F sea una función cuadrática podemos expresarla en forma matricial como sigue:

$$F(\mathbf{x}) = \mathbf{x}'\mathbf{Q}\mathbf{x} + \mathbf{c}'\mathbf{x} + d,$$

donde $\mathbf{x}'$ denota al vector traspuesto de $\mathbf{x} \in \mathbb{R}^n$,$\mathbf{Q} \in \mathbb{R}^{n\times n}$, $\mathbf{c} \in \mathbb{R}^n$ y $d \in \mathbb{R}$. Si además las restricciones vienen dadas por funciones lineales, estas se podrán expresar como:

$$\mathbf{A}\mathbf{x} \leq \mathbf{b}, \tag{5}$$

entendiendo la desigualdad 5 componente a componente ($\mathbf{A} \in \mathbb{R}^{m\times n}$ y $\mathbf{b} \in \mathbb{R}^m$, con n el número de variables y m el número de restricciones). El problema de optimizar la función con las restricciones descritas con anterioridad se puede formular como sigue para el caso de minimización:

$$\begin{aligned} &\text{mín } \frac{1}{2}\mathbf{x}'\mathbf{Q}\mathbf{x} + \mathbf{c}'\mathbf{x} \\ &s.a.\ \mathbf{A}\mathbf{x} \leq \mathbf{b} \end{aligned}$$

A este tipo de problemas de optimización se les denomina problema de optimización cuadrática o programación cuadrática (QP). Especialmente importante es el caso en el que la matriz $\mathbf{Q}$ es definida positiva. En dicha situación, el problema es un problema de optimización convexa, los cuales presentan propiedades que hacen posible su resolución de manera eficiente. Dichos problemas se denominan problemas QP convexos.

2.2. Modelo de Media-Varianza de Markowitz

El modelo de optimización de carteras de Media-Varianza (MV), fundamental en la economía financiera, fue propuesto originalmente por Markowitz en 1952 [29]. Este modelo de un solo período tiene como objetivo optimizar el equilibrio entre la media (retorno) y la varianza (riesgo) de una cartera. El modelo calcula los pesos de inversión (w_n) óptimos para N activos basándose en sus retornos esperados (μ_n), riesgos (σ_m) y covarianzas (σ_{mn}). La media y la

varianza de la cartera se representan como:

$$\sum_{n=1}^{N} w_n \mu_n, \quad \text{y} \quad \sum_{n,m=1}^{N} w_n w_m \sigma_{nm} \quad (\text{donde} \quad \sigma_{nn} = \sigma_n^2).$$

La teoría abarca dos objetivos principales: maximizar retornos y minimizar riesgos, tratados como problemas de optimización separados. La cartera de Máximo Retorno Global (GMR por sus siglas en inglés), aunque maximiza retornos, no incorpora ningún mecanismo de diversificación [12]. En contraste, la cartera de Mínima Varianza Global (GMV por sus siglas en inglés), ampliamente utilizada por su simplicidad, se enfoca únicamente en minimizar el riesgo [28, 5].

El perfil de aversión al riesgo del inversor se incorpora como un hiperparámetro $\lambda_\sigma \in \mathbb{R}^+$, equilibrando la importancia del riesgo frente al retorno medio. El modelo de optimización se expresa como:

$$\begin{aligned} \min_{w_1,\ldots,w_N} \quad & \lambda_\sigma \sum_{n,m=1}^{N} w_n w_m \sigma_{nm} - \sum_{n=1}^{N} w_n \mu_n. \\ \text{s.a.} \quad & \sum_{n=1}^{N} w_n = 1, \\ & w_1, \ldots, w_N \geq 0. \end{aligned}$$

O de forma matricial como:

$$\begin{aligned} \min_{\mathbf{w}\in\mathbb{R}} \quad & \lambda_\sigma \mathbf{w}' \boldsymbol{\Sigma} \mathbf{w} - \mathbf{w}' \boldsymbol{\mu} \\ \text{s.a.} \quad & \mathbf{1}_N' \mathbf{w} = 1, \\ & \mathbf{w} \geq 0. \end{aligned}$$

Al ajustar el parámetro de tolerancia al riesgo λ_σ en todo el espectro no negativo de los números reales y al minimizar el problema de optimización, se obtiene la utilidad esperada que describe la frontera no dominada de Markowitz dentro del espacio de varianza y retorno esperado. Es decir, este proceso permite encontrar un equilibrio óptimo entre el riesgo y el retorno esperado en la construcción de la cartera, lo que resulta en una distribución eficiente de los activos en el portafolio.

2.3. Calificación ESG

La calificación o puntuación ESG, es una medida que evalúa el desempeño de una empresa o un activo financiero en términos de criterios ambientales, sociales y de gobernanza (ESG por sus siglas en inglés: *Environmental, Social and Governance*). Estos criterios se utilizan para evaluar el impacto y la sostenibilidad de una empresa en áreas clave que van más allá de los aspectos financieros:

- **Ambientales**: Estos criterios evalúan cómo una empresa maneja su impacto ambiental. Pueden incluir aspectos como las emisiones de gases de efecto invernadero, el consumo de agua, la gestión de residuos, la eficiencia energética, el cambio climático y la conservación de recursos naturales. Las empresas con altos estándares ambientales suelen tener políticas y prácticas que minimizan su impacto en el medio ambiente y trabajan hacia la sostenibilidad a largo plazo.

- **Sociales**: Estos criterios se centran en cómo una empresa gestiona las relaciones con sus empleados, clientes, proveedores, comunidades locales y la sociedad en general. Pueden incluir aspectos como la igualdad de género, la diversidad e inclusión en el lugar de trabajo, la seguridad laboral, los derechos humanos, las prácticas laborales justas, el compromiso comunitario y el impacto social positivo. Las empresas con altos estándares sociales suelen promover un entorno laboral seguro y equitativo, respetar los derechos humanos y contribuir al bienestar de las comunidades en las que operan.

- **Gobernanza**: Estos criterios evalúan la estructura de gobierno de una empresa y cómo se manejan los aspectos relacionados con la transparencia, la ética, la gestión de riesgos y la responsabilidad corporativa. Pueden incluir aspectos como la independencia de la junta directiva, la remuneración de los ejecutivos, la divulgación financiera, la prevención de conflictos de interés, la gestión de riesgos y la ética empresarial. Las empresas con un buen gobierno corporativo suelen tener estructuras de liderazgo sólidas, prácticas transparentes y una cultura de responsabilidad empresarial.

La puntuación ESG asigna una puntuación numérica o una calificación a las empresas en función de su desempeño en estos tres ámbitos. Estas puntuaciones se utilizan para informar a los inversores sobre el riesgo y las oportunidades asociadas con las empresas en términos

de sostenibilidad. Los inversores pueden utilizar la puntuación ESG para tomar decisiones de inversión que estén alineadas con sus valores éticos y objetivos financieros a largo plazo. Además, también pueden influir en el costo de capital de una empresa y su acceso a financiamiento, ya que una mejor puntuación ESG puede indicar una gestión más sólida y menos riesgos potenciales.

2.4. Modelo Media-Varianza-ESG (MV(ESG))

El problema estándar de selección de cartera bicriterio tradicionalmente asume que los inversores priorizan alcanzar un nivel específico de rentabilidad, manteniendo niveles definidos de riesgo. A partir de principios de la década de 1970, numerosos académicos han intentado integrar un criterio adicional en la construcción de carteras, que va más allá de las métricas convencionales de retorno esperado y varianza [24, 38, 37]. Sin embargo, fue solo en los años 2000 que el concepto de integrar objetivos suplementarios ganó un impulso significativo dentro del marco metodológico [25, 1, 20].

Nos enfocaremos en la incorporación de la sostenibilidad como el tercer objetivo en el marco del modelo de Media-Varianza (MV). Este enfoque significa un cambio notable en la modelización financiera tradicional, enfatizando la integración de principios de desarrollo sostenible [6, 19, 40, 15]. El tercer objetivo relacionado con la sostenibilidad será incorporado en el modelo de Media-Varianza (MV) como una meta a maximizar, siguiendo el precedente establecido en trabajos anteriores [6, 40]. En consecuencia, el modelo de optimización se definirá de la siguiente manera:

$$
\begin{aligned}
\min_{w_1,\ldots,w_N} \quad & \lambda_\sigma \sum_{n,m=1}^{N} w_n w_m \sigma_{nm} - \sum_{n=1}^{N} w_n \mu_n - \lambda_{\text{ESG}} \sum_{n=1}^{N} w_n s_n. \\
\text{s.a.} \quad & \sum_{n=1}^{N} w_n = 1, \\
& w_1, \ldots, w_N \geq 0.
\end{aligned}
$$

donde $s_1, \ldots, s_N$ es un vector de puntuaciones ESG de activos individuales y $\lambda_{\text{ESG}} \in \mathbb{R}_+$ es la tolerancia al riesgo del inversionista con respecto a la responsabilidad social. Modificar el par de tolerancia al riesgo $(\lambda_\sigma, \lambda_{ESG})$ dentro del dominio no negativo de $\mathbb{R}^2$ y posteriormente

minimizar el problema de optimización, hace que la utilidad esperada produzca una superficie no dominada en el espacio de Media-Varianza-ESG. Específicamente, cuando $\lambda_\sigma \to \infty$ con λ_{ESG} constante, la minimización de la función objetivo produce la cartera GMV. En contraste, cuando $\lambda_{ESG} \to \infty$ con λ_σ constante, se obtiene una cartera máxima ESG. La cartera GMR se obtiene cuando $\lambda_\sigma = \lambda_{ESG} = 0$.

2.5. Discrepancia entre agencias de calificación de criterios ESG

A diferencia de la información financiera, donde el desarrollo de estándares de reporte ha llevado a cierto grado de consenso entre los inversores, la información de sostenibilidad aún carece de estandarización y formalización, y en muchos casos la evaluación de la sostenibilidad invita a más que una justa dosis de subjetividad. Mientras los datos siguen evolucionando, organizaciones como la Iniciativa de Reporte Global (GRI), la Junta de Normas de Contabilidad Sostenible (SASB) y el Grupo de Trabajo sobre Divulgaciones Financieras Relacionadas con el Clima (TCFD) han fomentado la transparencia a nivel empresarial y continúan ayudando a impulsar un marco hacia una mayor estandarización en el reporte [27].

Las inconsistencias entre las agencias de calificación ESG no son solo un problema de definiciones. Al menos otras dos razones pueden llevar a los proveedores de calificaciones a puntuar de manera diferente a la misma empresa.

En primer lugar, los proveedores de calificaciones pueden no estar de acuerdo sobre cómo medir el mismo factor ESG. A pesar de los esfuerzos de organizaciones como las mencionadas en el parrafo anterior por establecer estándares, no existe un enfoque universalmente aceptado para medir indicadores no financieros. Las agencias de calificación emplean cientos de variables relacionadas con ESG. Algunas provienen de informes de empresas y presentaciones regulatorias y, por lo tanto, deberían ser consistentes entre agencias. Sin embargo, muchas otras provienen de entrevistas o cuestionarios y de informes independientes de terceros con enfoques potencialmente conflictivos.

En segundo lugar, incluso si las agencias están de acuerdo sobre cómo medir diferentes factores relacionados con ESG, cada agencia ha desarrollado su propia metodología para decidir qué indicadores relacionados con ESG considerar y cómo agregarlos en una puntuación general. Esta diversidad de metodologías puede llevar a variaciones significativas en las puntuaciones finales de ESG de una empresa, lo que dificulta la comparación entre agencias y la

interpretación de los resultados. Es crucial reconocer estas diferencias metodológicas al analizar las calificaciones ESG y considerarlas al tomar decisiones de inversión o evaluación de riesgos [26].

Muchos inversores y analistas están tentados a tratar las calificaciones ESG como las calificaciones crediticias corporativas. En sentido estricto, las calificaciones ESG intentan cuantificar la exposición de una empresa a ciertos riesgos comerciales. A medida que se asigna más capital dentro de un marco ESG, estas calificaciones comenzarán a afectar el costo de capital de una empresa. Sin embargo, la correlación entre las agencias de calificación ESG es bastante débil, 0.40, en contraste con la correlación de las calificaciones crediticias que es bastante fuerte, en 0.90. Esto impacta la capacidad de las calificaciones ESG para reflejarse adecuadamente en los precios de las acciones corporativas, ya que los inversores enfrentan desafíos al tratar de identificar a los superadores frente a los rezagados. Incluso si una gran parte de los inversores prefiere invertir en empresas con una calificación ESG sólida, la divergencia de las calificaciones dispersa el efecto de estas preferencias en los precios de los activos. Teniendo esto en cuenta, parece más apropiado comparar las calificaciones ESG con las recomendaciones de los analistas de valores del lado de la venta, donde algunos pueden recomendar "comprar" y otros "vender" basados en la misma o similar información financiera [27].

Es debido a estas discrepancias que se proponen a continuación modelos con los que no solo integrar los criterios ESG para la optimización de las carteras de inversión sino además estimar qué importancia debe de darse a cada agencia de calificación para maximizar la valoración ESG sin dejar atrás los criterios puramente financieros.

2.6. Modelo de Media-Varianza-ESG multiagencia

En esta sección, delineamos el modelo de optimización de cartera multiagencia que se propone en el presente TFG, que acomoda múltiples evaluadores para calificaciones ESG. Con la introducción de diversas agencias de calificación ESG, el vector previamente definido $\mathbf{s} \in \mathbb{R}^N$ se expande en una matriz de dimensión $\mathbb{R}^{D\times N}$, donde D representa el número de agencias de calificación ESG incluidas en el análisis. En consecuencia, los componentes de la matriz $s_{dn} \in \mathbb{R}_+$ están indexados por $d \in \{1,\dots,D\}$ y $n \in \{1,\dots,N\}$. El modelo ahora requiere la estimación de dos tipos distintos de vectores: el vector de peso de activos para la cartera, denotado por $\mathbf{w}^p = (w_1^p,\dots,w_N^p) \in \mathbb{R}^N$, y el vector de peso asignado a las agencias de cali-

ficación ESG, representado como $\mathbf{w}^s = (w_1^s, \ldots, w_D^s) \in \mathbb{R}^D$. Consecuentemente, el problema de optimización se define de la siguiente manera:

$$\begin{aligned}
\min_{\substack{w_1^p,\ldots,w_N^p \\ w_1^s,\ldots,w_D^s}} \quad & \lambda_\sigma \sum_{n,m=1}^{N} w_n^p w_m^p \sigma_{nm} - \sum_{n=1}^{N} w_n^p \mu_n - \lambda_{\text{ESG}} \sum_{n=1}^{N} w_n^p \sum_{d=1}^{D} w_d^s s_{dn}. \\
\text{s.a.} \quad & \sum_{n=1}^{N} w_n^p = 1, \\
& \sum_{d=1}^{D} w_d^s = 1, \\
& w_1^p, \ldots, w_N^p \geq 0, \\
& w_1^s, \ldots, w_D^s \geq 0.
\end{aligned}$$

Como se puede observar en la ecuación para el vector $\mathbf{w}^s$, también se han incorporado restricciones para garantizar que sus elementos sean mayores que cero y que la suma de sus elementos sea igual a uno.

A medida que λ_σ aumenta hacia el infinito, el problema de optimización se convierte principalmente en minimizar la varianza, lo que hace que el componente de sostenibilidad ESG (involucrando $\mathbf{w}^s$) sea irrelevante. El resultado depende únicamente de $\mathbf{w}^p$ para reducir la varianza.

Por el contrario, con λ_{ESG} tendiendo hacia el infinito, $\mathbf{w}^s$ prioriza las agencias que califican favorablemente la sostenibilidad de los activos en términos ESG. En consecuencia, $\mathbf{w}^p$ preferirá activos con calificación ESG más altos, centrándose en maximizar la sostenibilidad ESG.

Cuando tanto λ_σ como λ_{ESG} se establecen en cero en el problema de optimización, el enfoque se desplaza exclusivamente hacia la maximización de los rendimientos, representados por el término $-\sum_{n=1}^{N} w_n^p \mu_n$. El vector $\mathbf{w}^p$ se configurará únicamente para maximizar los rendimientos esperados. En este escenario, $\mathbf{w}^s$ se vuelve irrelevante para el resultado de la optimización, ya que no afecta la maximización de los retornos.

Cuando $0 < \lambda_\sigma, \lambda_{\text{ESG}} < \infty$ en el problema de optimización, $\mathbf{w}^s$ y $\mathbf{w}^p$ se configuran para maximizar la interacción entre los términos de la función. Esto implica equilibrar los objetivos de riesgo, retorno y sostenibilidad ESG.

El modelo también puede formularse en forma matricial de la siguiente manera:

$$\begin{aligned} \min_{\substack{\mathbf{w}^p \in \mathbb{R}^N \\ \mathbf{w}^s \in \mathbb{R}^D}} \quad & \lambda_\sigma (\mathbf{w}^p)' \boldsymbol{\Sigma} \mathbf{w}^p - (\mathbf{w}^p)' \boldsymbol{\mu} - \lambda_{\text{ESG}} (\mathbf{w}^p)' (\mathbf{S}' \mathbf{w}^s). \\ \text{s. a.} \quad & \mathbf{1}_N' \mathbf{w}^p = 1. \\ & \mathbf{1}_D' \mathbf{w}^s = 1. \\ & \mathbf{w}^p \geq \mathbf{0}_N, \\ & \mathbf{w}^s \geq \mathbf{0}_D, \end{aligned} \tag{6}$$

donde $\boldsymbol{\Sigma} \in \mathbb{R}^{N \times N}$ es la matriz de covarianza de los rendimientos de los activos (en otras palabras, la matriz de riesgo de los activos), $\boldsymbol{\mu} = (\mu_1 \dots \mu_N)^T \in \mathbb{R}^N$ es el vector con los rendimientos esperados, $\mathbf{S} \in \mathbb{R}^{D \times N}$ representa la matriz de puntuación ESG de las D agencias de calificación consideradas para evaluar los N activos, y $\mathbf{0}_N$, $\mathbf{0}_D$ y $\mathbf{1}_N$, $\mathbf{1}_D$ son vectores de N y D dimensiones con ceros y unos en todas las filas, respectivamente.

El problema de optimización se redefinirá utilizando un vector $\mathbf{x}$ que contiene los dos parámetros para la estimación: $\mathbf{x} = (\mathbf{w}^p, \mathbf{w}^s) \in \mathbb{R}^{N+D}$. Además, se introducen dos matrices auxiliares:

(i) la matriz $\mathbf{A}$, definida como:

$$\mathbf{A} = \begin{pmatrix} \mathbf{0}_{N \times D} \\ \mathbf{I}_D \end{pmatrix} \in \mathbb{R}^{(N+D) \times D},$$

(ii) la matriz $\mathbf{B}$, definida como:

$$\mathbf{B} = \begin{pmatrix} \mathbf{I}_N \\ \mathbf{0}_{D \times N} \end{pmatrix} \in \mathbb{R}^{(N+D) \times N},$$

resultando en el siguiente problema de optimización:

$$\begin{aligned} \min_{\mathbf{x}\in\mathbb{R}^{N+D}} \quad & \lambda_\sigma \mathbf{x}'\mathbf{B}\boldsymbol{\Sigma}\mathbf{B}'\mathbf{x} - \mathbf{x}'\mathbf{B}\boldsymbol{\mu} - \lambda_{\text{ESG}}\mathbf{x}'\mathbf{A}\mathbf{S}\mathbf{B}'\mathbf{x}. \\ \text{s. a.} \quad & \begin{pmatrix} \mathbf{1}_N \\ \mathbf{0}_D \end{pmatrix}' \mathbf{x} = 1. \\ & \begin{pmatrix} \mathbf{0}_N \\ \mathbf{1}_D \end{pmatrix}' \mathbf{x} = 1. \\ & \mathbf{x} \geq \mathbf{0}_{N+D}. \end{aligned} \tag{7}$$

Donde en la última restricción, la desigualdad se entiende componente a componente.

Para facilitar la referencia, el problema de optimización de cartera propuesto se expresa como:

$$\begin{aligned} \min_{\mathbf{x}\in\mathbb{R}^{N+D}} \quad & \frac{1}{2}\mathbf{x}'\mathbf{H}\mathbf{x} - \mathbf{x}'\mathbf{D}. \\ \text{s. a.} \quad & \begin{pmatrix} \mathbf{1}_N \\ \mathbf{0}_D \end{pmatrix}' \mathbf{x} = 1. \\ & \begin{pmatrix} \mathbf{0}_N \\ \mathbf{1}_D \end{pmatrix}' \mathbf{x} = 1. \\ & \mathbf{x} \geq \mathbf{0}_{N+D}, \end{aligned} \tag{8}$$

donde $\mathbf{D} = \mathbf{B}\boldsymbol{\mu}$ y $\mathbf{H} = (\mathbf{C} + \mathbf{C}')$, siendo $\mathbf{C}$ la matriz asociada con el componente cuadrático del problema de optimización, dado por $\mathbf{C} = (\lambda_\sigma \mathbf{B}\boldsymbol{\Sigma}\mathbf{B}' - \lambda_{\text{ESG}}\mathbf{A}\mathbf{S}\mathbf{B}')$. Esta reformulación matricial se lleva a cabo para garantizar que el término cuadrático sea simétrico, un requisito considerado crucial en el contexto de la mayoría de los problemas de optimización.

2.6.1. Características del modelo.

La convexidad del problema de optimización depende críticamente de las características de la matriz $\mathbf{H}$. Para que el problema sea convexo, $\mathbf{H}$ debe ser tanto simétrica como semidefinida positiva. La simetría de $\mathbf{H}$ es evidente por construcción ya que $\mathbf{H}' = (\mathbf{C} + \mathbf{C}')' = (\mathbf{C} + \mathbf{C}') = \mathbf{H}$. Sin embargo, no tenemos que $\mathbf{H}$ sea semidefinida positiva. Mientras que la componente $\lambda_\sigma \mathbf{B}\boldsymbol{\Sigma}\mathbf{B}'$ en $\mathbf{C}$ es semidefinida positivo debido a que $\boldsymbol{\Sigma}$ es estrictamente positiva, el término $-\lambda_{\text{ESG}}\mathbf{A}\mathbf{S}\mathbf{B}'$ no se puede garantizar que sea semidefinido positivo, lo que potencialmente hace

que la matriz $\mathbf{H}$ no sea definida positiva.

Este problema de optimización es un problema cuadrático no convexo con restricciones de igualdad y desigualdad lineales, lo que lo hace complejo y no adecuado para métodos tradicionales de optimización convexa. Para abordar esto, se proponen algoritmos basados en poblaciones. Estos algoritmos destacan en navegar espacios complejos y no convexos y pueden manejar restricciones para garantizar soluciones viables, lo que los hace ideales para este problema.

2.6.2. Limitaciones del modelo

El algoritmo requiere la estimación de los hiperparámetros λ_{ESG} y λ_σ, los cuales son integrales en un contexto de gestión de carteras donde el objetivo es garantizar la interacción entre los pesos asignados a las agencias de calificación y los de la cartera. Un enfoque lógico para optimizar estos parámetros sería maximizar el índice de Sharpe, una métrica ampliamente reconocida para evaluar el rendimiento ajustado al riesgo de una cartera de inversiones. Sin embargo, una desventaja potencial de esta metodología es la posibilidad de obtener soluciones donde λ_{ESG} se aproxime a cero, lo que haría que el vector de pesos de las agencias de calificación fuera inconsecuente en el problema de optimización. Para mitigar este problema, sería prudente introducir una estrategia secundaria que considere la importancia relativa de este tercer objetivo en comparación con los otros dos. Este enfoque de doble estrategia no solo optimizaría el rendimiento de la cartera con respecto al índice de Sharpe, sino que también garantizaría la importancia de los pesos de las agencias de calificación en el marco de optimización general. A continuación presentaremos un modelo siguiendo este enfoque en dos etapas.

2.7. Modelo de Media-Varianza-ESG multiagencia de dos etapas

En esta sección, delineamos el modelo de optimización de cartera multiagente, que acomoda múltiples evaluadores para valoraciones de ESG. Con la introducción de diversas agencias de calificación ESG, el vector previamente definido $\mathbf{s} \in \mathbb{R}^N$ se expande en una matriz $\mathbf{S} \in \mathbb{R}^{D\times N}$, donde D representa el número de agencias de calificación ESG incluidas en el análisis. En consecuencia, los componentes de la matriz $s_{dn} \in \mathbb{R}_+$ están indexados por

$d \in \{1, \ldots, D\}$ y $n \in \{1, \ldots, N\}$.

El modelo ahora requiere la estimación de dos tipos distintos de vectores: el vector de pesos de activos para la cartera, denotado por $\mathbf{w}^p = (w_1^p, \ldots, w_N^p) \in \mathbb{R}^N$, y el vector de pesos asignados a las agencias de calificación ESG, representado como $\mathbf{w}^s = (w_1^s, \ldots, w_D^s) \in \mathbb{R}^D$. El método propuesto implica una estimación de dos etapas de los vectores $\mathbf{w}^p$ y $\mathbf{w}^s$. Inicialmente, $\mathbf{w}^p$ se optimiza para maximizar el índice de Sharpe, enfocándose en el rendimiento financiero. Posteriormente, $\mathbf{w}^s$ se determina buscando mejorar la interacción entre los pesos de la cartera y la sostenibilidad, según lo informado por las agencias.

2.7.1. Primera etapa

En la primera fase, el objetivo es maximizar el Índice de Sharpe, asegurando que los elementos de la cartera sumen uno y que cada inversión sea mayor que cero, prohibiendo así posiciones en corto. El desafío del problema de optimización radica en su naturaleza no cuadrática y compleja. Por lo tanto, se adopta un enfoque de cartera de Varianza Media Cuadrada (MSV) al cuadrar el rendimiento medio y eliminar la raíz cuadrada de la desviación estándar de la volatilidad. Esta transformación, al ser una función monótonamente creciente, garantiza que el comportamiento y la solución óptima se alineen con la maximización del Índice de Sharpe original. Por simplicidad, se prefiere este último enfoque. En forma matricial, el modelo se representa de manera concisa como sigue:

$$\begin{aligned} \max_{\mathbf{w}^p \in \mathbb{R}^N} \quad & \frac{\left((\mathbf{w}^p)' \boldsymbol{\mu}\right)^2}{(\mathbf{w}^p)' \boldsymbol{\Sigma} \mathbf{w}^p} \\ \text{s. a.} \quad & \mathbf{1}_N' \mathbf{w}^p = 1. \\ & \mathbf{w}^p \geq \mathbf{0}_N, \end{aligned}$$

donde $\mathbf{0}_N$ y $\mathbf{1}_N$ son vectores de N dimensiones con ceros y unos en todas las filas, respectivamente.

En el renombrado artículo "Sobre la programación fraccionaria no lineal"de W. Dinkelbach (1967) [10], se demuestra que un problema de optimización de la forma máx $\left\{\frac{N(x)}{D(x)}, x \in S\right\}$ puede reformularse como máx $\{N(x) - \lambda D(x), x \in S\}$ siempre que $S \subset \mathbb{R}^N$ sea un conjunto convexo y compacto, $\lambda \in \mathbb{R}$, y tanto N como D sean funciones continuas en S con $D > 0$. Se observa que el problema de optimización bajo consideración cumple con estos criterios: el

espacio de restricciones es convexo y compacto, y tanto la función de media cuadrática como la varianza son continuas, con la varianza siendo estrictamente mayor que cero. Por lo tanto, el problema de optimización se puede reformular de la siguiente manera:

$$\begin{aligned} \min_{\mathbf{w}^p \in \mathbb{R}^N} \quad & F(\lambda) = \lambda (\mathbf{w}^p)' \boldsymbol{\Sigma} \mathbf{w}^p - (\mathbf{w}^p)' \boldsymbol{\mu} \boldsymbol{\mu}' \mathbf{w}^p \\ \text{s. a.} \quad & \mathbf{1}_N' \mathbf{w}^p = 1. \\ & \mathbf{w}^p \geq \mathbf{0}_N, \end{aligned}$$

donde $\lambda \in \mathbb{R}$ es un hiperparámetro que pondera la importancia de los dos objetivos. También es crucial enfatizar que en el estudio mencionado anteriormente, se demuestra que la ecuación $F(\lambda) = 0$ tiene una solución única λ_0. Además, se cumple que $\lambda_0 = \frac{N(x_0)}{D(x_0)} = \text{máx} \left\{ \frac{N(x)}{D(x)}, x \in S \right\}$. Por lo tanto, se debe buscar un valor de λ que haga que la función objetivo sea cero, ya que esto resultaría en la maximización del Índice de Sharpe, que es el objetivo final.

Finalmente, para facilitar la referencia, la cartera propuesta se expresa como:

$$\begin{aligned} \min_{\mathbf{w}^p \in \mathbb{R}^N} \quad & (\mathbf{w}^p)' \mathbf{H} \mathbf{w}^p. \\ \text{s. a.} \quad & \mathbf{1}_N' \mathbf{w}^p = 1. \\ & \mathbf{w}^p \geq \mathbf{0}_N, \end{aligned}$$

con $\mathbf{H} = \lambda \boldsymbol{\Sigma} - \mathbf{R} \in \mathbb{R}^{N \times N}$ y $\mathbf{R} = \boldsymbol{\mu} \boldsymbol{\mu}' \in \mathbb{R}^{N \times N}$.

2.7.2. Características del modelo

La matriz $\mathbf{H}$ en el problema de programación cuadrática (QP) asociado al modelo es la diferencia entre dos matrices ponderadas positivamente ($\boldsymbol{\Sigma}$ y $\mathbf{R}$). En este contexto, no se puede asegurar la positividad de $\mathbf{H}$ y el problema de QP asociado puede ser un problema de QP no convexo. Para abordar esto, se proponen algoritmos evolutivos (EAs) con capacidades de manejo de restricciones. Estos algoritmos destacan en la navegación de espacios complejos y no convexos y pueden manejar restricciones para garantizar soluciones factibles, lo que los hace ideales para este problema.

2.7.3. Segunda etapa

En la segunda fase del enfoque, se busca maximizar la interacción entre el vector de pesos de la cartera y el vector de sostenibilidad, ponderado por el vector $\mathbf{w}^s$. En esta etapa, se asume que el vector $\mathbf{w}^p$ ya está estimado y, por lo tanto, se considera fijo. En consecuencia, el problema de optimización se puede formular de la siguiente manera:

$$\begin{aligned} \underset{w_1^s,\ldots,w_D^s}{\text{máx}} \quad & \sum_{n=1}^{N} w_n^p \sum_{d=1}^{D} w_d^s s_{dn}. \\ \text{s.a.} \quad & \sum_{d=1}^{D} w_d^s = 1, \\ & w_1^s, \ldots, w_D^s \geq 0, \end{aligned}$$

con la siguiente forma matricial:

$$\begin{aligned} \underset{\mathbf{w}^s \in \mathbb{R}^D}{\text{máx}} \quad & (\mathbf{w}^p)' \mathbf{S}' \mathbf{w}^s. \\ \text{s. a.} \quad & \mathbf{1}_D' \mathbf{w}^s = 1. \\ & \mathbf{w}^s \geq \mathbf{0}_D, \end{aligned}$$

donde $\mathbf{0}_D$ y $\mathbf{1}_D$ son vectores de D dimensiones con ceros y unos en todas las filas, respectivamente.

2.7.4. Solución del problema

El problema de optimización previamente delineado puede interpretarse como un problema de optimización lineal con una solución sencilla para estimar el vector $\mathbf{w}^s$. Específicamente, el elemento d-ésimo de $\mathbf{w}^s$ es 1 si y solo si el d-ésimo elemento del producto $(\mathbf{w}^p)'\mathbf{S}'$ es el valor máximo de este vector, y 0 en caso contrario. Esto puede expresarse matemáticamente de la siguiente manera:

$$w_d^s = \begin{cases} 1 & \text{si } d = \arg\text{máx}_d((\mathbf{w}^p)'\mathbf{S}')_d \\ 0 & \text{en otro caso} \end{cases},$$

donde $((\mathbf{w}^p)'\mathbf{S}')_d$ denota el d-ésimo elemento del vector resultante $(\mathbf{w}^p)'\mathbf{S}'$, y $\arg\text{máx}_d((\mathbf{w}^p)'\mathbf{S}')_d$ identifica la posición d en la que el vector alcanza su valor máximo.

Por lo tanto, el vector $\mathbf{w}^s$ sirve como un vector de selección que identifica la agencia de sostenibilidad cuyos criterios están más alineados con la composición actual de la cartera. Esta alineación se determina en función del producto máximo de los pesos de la cartera y las calificaciones de sostenibilidad.

3

Algoritmos basados en poblaciones

Los algoritmos evolutivos (EAs) constituyen una categoría de métodos de optimización que encuentran su fundamento en los principios de la evolución natural, emulando procesos biológicos como la selección natural, la mutación y la recombinación genética. Estos algoritmos, al ser inspirados en la naturaleza, se destacan por su capacidad para adaptarse y evolucionar soluciones a lo largo del tiempo, permitiendo la exploración eficiente de espacios de búsqueda complejos y multidimensionales. Su diseño está especialmente orientado a abordar problemas de optimización que, debido a su complejidad, no pueden ser resueltos de manera efectiva mediante técnicas tradicionales de búsqueda o algoritmos determinísticos. La robustez de los algoritmos evolutivos radica en su enfoque poblacional, donde múltiples soluciones candidatas se evalúan y evolucionan simultáneamente, favoreciendo la convergencia hacia soluciones cercanas al óptimo global, incluso en problemas con múltiples óptimos locales. Este enfoque metaheurístico permite exigir mínimas hipótesis sobre la función a optimizar [16].

La historia de los algoritmos evolutivos se remonta a mediados del siglo XX, cuando los primeros trabajos en computación y teoría evolutiva comenzaron a converger. Uno de los pioneros en este campo fue el científico alemán Ingo Rechenberg, quien en la década de 1960 desarrolló la Estrategia Evolutiva (*Evolution Strategy*, ES) para optimizar parámetros en procesos técnicos [34]. De forma paralela, John Holland, un investigador estadounidense, introdujo en la década de 1970 los Algoritmos Genéticos (AG), una metodología inspirada en la genética y la selección natural, que rápidamente ganó popularidad debido a su flexibilidad y eficiencia en una amplia gama de aplicaciones [21].

Algorithm 1 Algoritmo basados en poblaciones

Inicialización:
$t \leftarrow 0$
Generar una población inicial $P(t)$ con N individuos
Evaluar la aptitud $f(x)$ de cada individuo $x \in P(t)$
while criterio de parada no esté satisfecho **do**
    Selección:
    Seleccionar un conjunto de individuos padres $S(t) \subseteq P(t-1)$
    Cruzamiento:
    Generar una nueva población $O(t)$ aplicando cruzamiento a los individuos de $S(t)$
    Mutación:
    Aplicar mutación a los individuos en $O(t)$ para obtener $O'(t)$
    Evaluación:
    Evaluar la aptitud $f(x)$ de cada individuo $x \in O'(t)$
    Reemplazo:
    Crear la nueva población $P(t)$ combinando individuos de $P(t-1)$ y $O'(t)$
    $t \leftarrow t+1$
end while
Resultado:
Retornar el mejor individuo x^* de $P(t)$ para cualquier t.

Dentro de los algoritmos evolutivos podemos distinguir entre distintos tipos:

- **Algoritmos Genéticos (AG)**: Inspirados en la biología evolutiva, estos algoritmos emplean operadores como la selección, el cruce (crossover) y la mutación para generar nuevas soluciones a partir de un conjunto inicial, denominado población.

- **Estrategias Evolutivas (ES)**: Estos algoritmos se centran en la optimización continua de problemas, utilizando principalmente operadores de mutación y selección. Son muy eficaces para la optimización de parámetros en sistemas de ingeniería.

- **Programación Evolutiva (EP)**: Enfocada en la evolución de máquinas de estados finitos, la programación evolutiva fue desarrollada por Lawrence J. Fogel en la década de 1960. Este método se diferencia de otros algoritmos evolutivos en que no utiliza operadores de cruce, sino que se basa en la mutación y la selección [13].

- **Programación Genética (GP)**: Desarrollada por John Koza en la década de 1990, la programación genética es una extensión de los algoritmos genéticos que se utiliza para evolucionar programas informáticos u otras representaciones funcionales [11].

3.1. Covariance Matrix Adaptation Evolution Strategy (CMA-ES)

La Estrategia de Evolución con Adaptación de la Matriz de Covarianza (CMA-ES por sus siglas en inglés) [22] es un algoritmo evolutivo avanzado que ha demostrado ser altamente efectivo para resolver problemas complejos de optimización de alta dimensión, lo que lo hace particularmente relevante en el contexto de la optimización de carteras con criterios de sostenibilidad. CMA-ES es un método de optimización adaptativo que simula procesos evolutivos mediante la actualización iterativa de una distribución normal multivariante [17]. Este enfoque se diferencia de los algoritmos evolutivos tradicionales al centrarse en la desaleatorización, que minimiza el azar en la actualización de parámetros, y la acumulación, que utiliza información pasada para guiar las futuras direcciones de búsqueda. Al ajustar continuamente la media y la matriz de covarianza de su distribución de búsqueda, CMA-ES es capaz de aprender y explotar la estructura subyacente del problema de optimización, ajustando eficazmente las direcciones y los tamaños de los pasos para navegar por paisajes complejos, no lineales y no convexos.

En la optimización de carteras, especialmente cuando se incluyen criterios de sostenibilidad como los indicadores ambientales, sociales y de gobernanza (ESG), la función objetivo se vuelve multidimensional y multiobjetivo, a menudo involucrando objetivos conflictivos como maximizar los rendimientos mientras se minimizan los riesgos y el impacto ambiental. CMA-ES es particularmente adecuado para este tipo de tarea porque no asume ninguna forma específica para la función objetivo, lo que le permite navegar de manera adaptativa por paisajes de aptitud irregulares y complejos que caracterizan los problemas reales de optimización financiera. La capacidad del algoritmo para manejar correlaciones entre variables y su adaptación dinámica de la estrategia de búsqueda lo hacen especialmente útil para evolucionar carteras sostenibles que cumplan con diversos criterios de los inversores.

El algoritmo CMA-ES funciona generando una población de soluciones candidatas en cada iteración, evaluando su aptitud en función de los objetivos predefinidos y actualizando los parámetros de la distribución de búsqueda en función de los candidatos más exitosos. Este proceso de actualización implica la adaptación de la matriz de covarianza, que captura la forma y la orientación del espacio de búsqueda, lo que permite al algoritmo aprender las dependencias entre las variables y guiar los futuros pasos de búsqueda de manera más eficiente [4]. Los

principales parámetros de CMA-ES, como el tamaño de la población, el tamaño del paso y las tasas de adaptación de la matriz de covarianza, juegan un papel crítico en el equilibrio entre la exploración (búsqueda de nuevas áreas) y la explotación (refinamiento de áreas conocidas). El tamaño de la población determina la diversidad de las soluciones candidatas, influyendo en la capacidad del algoritmo para explorar ampliamente el espacio de soluciones, mientras que el tamaño del paso controla cuán agresivamente el algoritmo se mueve hacia los posibles óptimos.

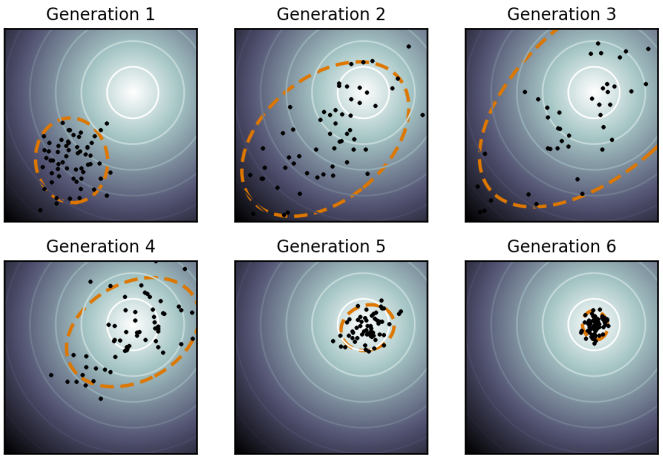


Figura 1: Interpretación geometrica de CMA-ES. *Wikipedia.*

El enfoque desaleatorizado de CMA-ES reduce la aleatoriedad en el ajuste de los parámetros de la estrategia, lo que conduce a una convergencia más consistente, especialmente en funciones mal escaladas y no separables, donde las estrategias evolutivas tradicionales pueden tener dificultades. La acumulación, otra característica clave de CMA-ES, aprovecha secuencias de pasos de búsqueda exitosos, en lugar de pasos individuales, para actualizar la matriz de covarianza y el tamaño del paso. Esto permite al algoritmo reconocer y favorecer los caminos de búsqueda que conducen a avances a lo largo del tiempo, mejorando la eficiencia del proceso de optimización.

Dado que los criterios ESG a menudo pueden entrar en conflicto con los objetivos financieros tradicionales, CMA-ES proporciona un marco robusto para equilibrar estos objetivos conflictivos al evolucionar soluciones que mejor cumplen con los requisitos multifacéticos de la gestión sostenible de carteras. La flexibilidad del algoritmo le permite explorar eficientemente los compromisos entre riesgo, retorno y sostenibilidad, convirtiéndolo en una gran

herramienta para optimizar decisiones de inversión que alineen tanto el desempeño financiero como las consideraciones éticas.

En resumen, las características clave de CMA-ES, actualización adaptativa de la matriz de covarianza, desaleatorización y acumulación [2], le permiten gestionar eficazmente las complejidades de problemas de optimización de carteras.

3.1.1. Principales parámetros

Los principales parámetros que gobiernan el comportamiento de la implementación del algoritmo usada en la biblioteca *Deap* [18] son:

- λ: El tamaño de la población determina cuántas nuevas soluciones candidatas se evalúan en cada generación.
- μ: El número de padres influye en la presión de selección y el grado de recombinación.
- w_i: Los pesos de recombinación controlan la contribución de cada individuo seleccionado a la nueva distribución.
- c_σ: La acumulación para el tamaño de paso ajusta la rapidez con la que el tamaño de paso se adapta al espacio de búsqueda.
- c_c: El parámetro de acumulación influye en la adaptación de la matriz de covarianza mediante el seguimiento de direcciones de búsqueda exitosas.
- d_σ: La amortiguación del tamaño de paso regula la tasa de cambio del tamaño de paso para mantener la estabilidad de la búsqueda.
- c_1: La tasa de aprendizaje para la actualización de rango uno controla la influencia de los pasos individuales en la matriz de covarianza.
- c_μ: La tasa de aprendizaje para la actualización de rango-μ ajusta la matriz de covarianza en función de los pasos seleccionados.
- σ_0: El tamaño de paso inicial debe elegirse en función de la escala del problema para equilibrar la exploración y la convergencia.

A continuación se da una tabla con los valores por defecto que ofrecen buenos resultados de manera general [18]:

Cuadro 1: Parámetros del Algoritmo CMA-ES y sus valores predeterminados [18]

Parámetro	**Símbolo**	**Valor Predeterminado**
Tamaño de la Población	λ	$\lambda = 4 + \lfloor 3 \cdot \log(n) \rfloor$
Número de Padres	μ	$\mu = \frac{\lambda}{2}$
Pesos de Recombinación	w_i	$w_i = \frac{\ln(\mu+\frac{1}{2})-\ln(i)}{\sum_{j=1}^{\mu}(\ln(\mu+\frac{1}{2})-\ln(j))}$ para $i \leq \mu$
Acumulación para el Tamaño de Paso	c_σ	$c_\sigma = \frac{\mu_{\text{eff}}+2}{n+\mu_{\text{eff}}+5}$
Acumulación para la Matriz de Covarianza	c_c	$c_c = \frac{4+\mu_{\text{eff}}/n}{n+4+2\mu_{\text{eff}}/n}$
Amortiguación del Tamaño de Paso	d_σ	$d_\sigma = 1 + 2\,\text{máx}\left(0, \sqrt{\frac{\mu_{\text{eff}}-1}{n+1}} - 1\right) + c_\sigma$
Tasa de Aprendizaje para la Matriz de Covarianza	c_1	$c_1 = \frac{2}{(n+1{,}3)^2+\mu_{\text{eff}}}$
Tasa de Aprendizaje para la Actualización de Rango-μ	c_μ	$c_\mu = \text{mín}\left(1 - c_1, \frac{2(\mu_{\text{eff}}-2+1/\mu_{\text{eff}})}{(n+2)^2+\mu_{\text{eff}}}\right)$
Tamaño de Paso Inicial	σ_0	Dependiente del problema

3.1.2. Flujo algoritmico

A continuación se ofrece pseudocódigo describiendo el flujo algorítmico de la implementación de CMA-ES que se usará:

Algorithm 2 Algoritmo CMA-ES

Entrada: Vector de media inicial $\mathbf{m}_0$, tamaño de paso inicial σ_0, tamaño de la población λ, número de padres μ
Inicializar:
    Establecer los pesos w_i para $i = 1, \ldots, \mu$ tales que $w_1 \geq w_2 \geq \ldots \geq w_\mu > 0$
    Calcular $\mu_{\text{eff}} = \frac{1}{\sum_{i=1}^{\mu} w_i^2}$
    Establecer las tasas de aprendizaje c_σ, c_c, c_1, c_μ según los valores predeterminados
    Inicializar el vector de media $\mathbf{m} = \mathbf{m}_0$, la matriz de covarianza $\mathbf{C} = \mathbf{I}$, el tamaño de paso $\sigma = \sigma_0$
    Inicializar las trayectorias de evolución $\mathbf{p}_c = \mathbf{0}$, $\mathbf{p}_\sigma = \mathbf{0}$
while no haya convergido **do**
    for $k = 1$ hasta λ **do**
        Muestra $\mathbf{z}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
        Transformar al espacio de búsqueda: $\mathbf{x}_k = \mathbf{m} + \sigma \mathbf{C}^{\frac{1}{2}} \mathbf{z}_k$
        Evaluar la aptitud: $f(\mathbf{x}_k)$
    end for
    Ordenar $\{\mathbf{x}_1, \ldots, \mathbf{x}_\lambda\}$ por aptitud y seleccionar los mejores μ individuos
    Actualizar la media: $\mathbf{m} = \sum_{i=1}^{\mu} w_i \mathbf{x}_i$
    Actualizar la trayectoria de evolución para la matriz de covarianza:
    $\mathbf{p}_c = (1 - c_c)\mathbf{p}_c + \sqrt{c_c(2 - c_c)\mu_{\text{eff}}} \cdot \mathbf{C}^{-\frac{1}{2}}(\mathbf{m} - \mathbf{m}_{\text{old}})/\sigma$
    Actualizar la matriz de covarianza:
    $\mathbf{C} = (1 - c_1 - c_\mu)\mathbf{C} + c_1 \mathbf{p}_c \mathbf{p}_c^T + c_\mu \sum_{i=1}^{\mu} w_i (\mathbf{x}_i - \mathbf{m})(\mathbf{x}_i - \mathbf{m})^T$
    Actualizar la trayectoria de evolución para el control del tamaño de paso:
    $\mathbf{p}_\sigma = (1 - c_\sigma)\mathbf{p}_\sigma + \sqrt{c_\sigma(2 - c_\sigma)\mu_{\text{eff}}} \cdot (\mathbf{C}^{-\frac{1}{2}}(\mathbf{m} - \mathbf{m}_{\text{old}})/\sigma)$
    Actualizar el tamaño de paso:
    $\sigma = \sigma \cdot \exp\left(\frac{c_\sigma}{d_\sigma}\left(\frac{\|\mathbf{p}_\sigma\|}{\mathbb{E}[\|\mathcal{N}(\mathbf{0},\mathbf{I})\|]} - 1\right)\right)$
    Guardar la media actual como la media anterior: $\mathbf{m}_{\text{old}} = \mathbf{m}$
end while
Return: el mejor individuo $\mathbf{x}$ encontrado.

3.2. Non-dominated sorting genetic algorithm (NSGA-II)

El Algoritmo Genético de Ordenamiento No Dominado II (NSGA-II), propuesto por Kalyanmoy Deb y sus colegas en el año 2000 [9], es un algoritmo evolutivo poderoso y ampliamente utilizado, diseñado para resolver problemas de optimización multiobjetivo. A diferencia de los métodos de optimización tradicionales, que buscan una única solución óptima, NSGA-II descubre de manera eficiente un conjunto de soluciones óptimas de Pareto, ofreciendo un equilibrio entre múltiples objetivos conflictivos. NSGA-II aborda específicamente tres principales desventajas de su predecesor (NSGA): alta complejidad computacional, falta de elitismo y la necesidad de un parámetro de compartición para mantener la diversidad [43]. NSGA-II in-

troduce mejoras significativas, incluyendo un enfoque rápido de ordenamiento no dominado, un mecanismo de distancia de amontonamiento para preservar la diversidad sin parámetros adicionales y una estrategia de selección elitista que mejora la convergencia y la distribución de las soluciones.

A continuación exponemos las principales características de este algoritmo [41]:

- **Ordenamiento No Dominado**: NSGA-II utiliza un algoritmo rápido de ordenamiento no dominado para clasificar las soluciones en diferentes niveles o frentes de no dominación. Una solución pertenece a un frente particular si no es dominada por ninguna otra solución en ese frente, pero domina a soluciones en frentes posteriores. El ordenamiento se realiza comparando cada solución con las demás, utilizando una estrategia de registro sofisticada que reduce comparaciones innecesarias, haciendo el proceso eficiente y escalable para grandes poblaciones.

- **Cálculo de la Distancia de Amontonamiento**: Para mantener la diversidad entre soluciones sin especificar un parámetro de compartición, NSGA-II utiliza la distancia de amontonamiento. Esta métrica estima la densidad de soluciones que rodean un punto particular calculando la distancia promedio de dos soluciones adyacentes a cada lado a lo largo de cada eje objetivo. Las soluciones en los límites del frente se asignan con una distancia infinita de amontonamiento para asegurar que los puntos extremos siempre se retengan. La distancia de amontonamiento ayuda a priorizar soluciones en regiones menos densas del espacio objetivo, lo que mejora la capacidad del algoritmo para mantener un frente de Pareto diverso.

- **Selección por torneo**: NSGA-II emplea un mecanismo de selección elitista que combina la población de padres, λ_t, y la población de descendientes, μ_t, para formar una población combinada, $(\lambda + \mu)_t$. La población combinada se ordena luego en base a la no dominación, y las soluciones se seleccionan frente a frente hasta que la nueva población de padres, λ_{t+1}, alcance el tamaño N. Si al agregar un frente completo se excede el tamaño requerido de la población, NSGA-II ordena las soluciones de ese frente según la distancia de amontonamiento y selecciona aquellas con los valores más altos de distancia, asegurando una selección bien distribuida y diversa de soluciones.

- **Cruce y mutación**: Después de formar la nueva población de padres, se aplican operadores genéticos como el cruzamiento y la mutación para crear los descendientes de la siguiente generación, μ_{t+1}. Estos operadores introducen variabilidad y permiten la exploración del espacio de búsqueda. NSGA-II utiliza típicamente cruzamiento binario simulado (SBX) y mutación polinómica, que son adecuadas para espacios de búsqueda continuos.

El mecanismo de funcionamiento de NSGA-II gira en torno a su capacidad para empujar simultáneamente la población hacia el verdadero frente de Pareto mientras mantiene una distribución diversa de soluciones a lo largo del frente. Al integrar el elitismo, asegura que las mejores soluciones encontradas en generaciones anteriores no se pierdan, mejorando significativamente la velocidad de convergencia y la calidad de las soluciones. Comparado con otros algoritmos como PAES (Estrategia Evolutiva Archivada de Pareto) y SPEA (Algoritmo Evolutivo de Fuerza Pareto), NSGA-II demuestra un rendimiento superior en mantener un frente de Pareto diverso y lograr una convergencia más cercana al verdadero frente óptimo de Pareto en varios problemas de referencia. Su enfoque sin parámetros para la gestión de la diversidad a través de la distancia de amontonamiento facilita su implementación y ajuste, permitiendo una aplicación más amplia en problemas complejos de optimización del mundo real sin la necesidad de ajustar manualmente los parámetros de nicho.

En general, la combinación de NSGA-II de un ordenamiento no dominado eficiente, selección elitista y preservación de la diversidad basada en la densidad lo convierte en uno de los algoritmos más robustos y confiables para la optimización multiobjetivo. Su eficiencia computacional y capacidad para producir un frente de Pareto bien distribuido han llevado a su adopción generalizada en varios campos, incluidos el diseño de ingeniería, finanzas y gestión ambiental, donde es necesario optimizar simultáneamente múltiples objetivos conflictivos [8].

3.2.1. Principales parámetros

Los principales parámetros que gobiernan el comportamiento de este algoritmo son:

Cuadro 2: Parámetros principales de NSGA-II y sus valores por defecto

Parámetro	**Símbolo**	**Valor por defecto**
Tamaño de población	N	100
Probabilidad de cruce	P_c	0.9
Probabilidad de mutación	P_m	$\frac{1}{n}$ (donde n es el número de variables)
Índice de distribución para cruce	η_c	20
Índice de distribución para mutación	η_m	20

- **Tamaño de población (N)**: Número de individuos en cada generación.
- **Probabilidad de cruce (P_c)**: Probabilidad de cruce entre pares de individuos.
- **Probabilidad de mutación (P_m)**: Probabilidad de mutación por cada gen en un individuo.
- **Índice de distribución para cruce (η_c)**: Controla la dispersión de los descendientes alrededor de los padres.
- **Índice de distribución para mutación (η_m)**: Controla la extensión de la mutación aplicada.

3.2.2. Flujo algoritmico

Algorithm 3 NSGA-II: Algoritmo Genético de Ordenamiento No Dominado II

Input: Tamaño de la población N, número de generaciones G
Output: Conjunto de soluciones Pareto-óptimas

Inicializar una población aleatoria P_0 de tamaño N
Evaluar la población P_0
for cada generación t de 0 a $G - 1$ **do**
    Generar la población de descendientes Q_t usando selección, cruzamiento y mutación
    Evaluar la población Q_t
    Combinar la población de padres y descendientes: $R_t = P_t \cup Q_t$
    Realizar el ordenamiento no dominado sobre R_t para encontrar frentes de no dominación $\{F_1, F_2, \ldots\}$
    Inicializar $P_{t+1} = \emptyset$
    $i = 1$
    while $|P_{t+1}| + |F_i| \leq N$ **do**
        Agregar el frente F_i completo a P_{t+1}: $P_{t+1} = P_{t+1} \cup F_i$
        $i = i + 1$
    end while
    Calcular la distancia de amontonamiento para cada solución en F_i
    Ordenar las soluciones de F_i según la distancia de amontonamiento en orden descendente
    Agregar las mejores soluciones de F_i a P_{t+1} hasta que $|P_{t+1}| = N$
end for
Return las soluciones en P_G

3.3. Particle Swarm Optimization (PSO)

El algoritmo *Particle Swarm Optimization* (PSO), Optimización por Enjambre de Partículas en español, es una técnica de optimización inspirada en el comportamiento social de los pájaros y peces, propuesto por Kennedy y Eberhart en 1995 [23]. En PSO, se colocan un número de entidades simples, las partículas, en el espacio de búsqueda de algún problema o función, y cada una evalúa la función objetivo en su ubicación actual [42]. El objetivo de esto es producir inteligencia computacional a través de las interacciones sociales entre las partículas que representarían a aves en una bandada o peces en un banco, en lugar de hacerlo únicamente a través de las capacidades cognitivas de un solo individuo.

Cada partícula luego determina su movimiento a través del espacio de búsqueda combinando algún aspecto de la historia de su ubicación actual y la mejor de su pasado, con las de

uno o más miembros del enjambre, junto con algunas perturbaciones aleatorias. La siguiente iteración tiene lugar después de que todas las partículas se hayan movido. Eventualmente, el enjambre en su conjunto, como una bandada de aves que colectivamente busca alimento, es probable que se acerque a un óptimo de la función de aptitud [36].

Cada individuo se encuentra conformado por tres vectores:

- La posición actual de la partícula.
- La mejor posición alcanzada por la partícula (*pbest*).
- La velocidad actual de la partícula.

De manera individual las partículas difícilmente pueden encontrar la solución óptima, sin embargo podemos permitir a la población que tengan una estructura de comunicación o topología que podemos pensar como un grafo (de manera general) no dirigido de manera que cada partícula puede saber la mejor posición alcanzada por las partículas adyacentes en este grafo.

Existen diversas topologías que se pueden elegir para generar los fenómenos emergentes que hacen que este algoritmo sea de utilidad pero podemos clasificarlas en dos grupos según si la topología cambia a lo largo de la ejecución o no, estáticas y dinámicas. A continuación exploraremos algunos ejemplos de cada grupo [33]:

1. **Topologías estáticas:**

   a) **Topología *gbest***: es la topología más simple a la par que una de las más usadas por su eficiencia. Esta topología podemos considerarla como aquella representada por un grafo completo (grafo con todos los vértices conectados entre si), lo que a efectos prácticos tan solo requiere que almacenemos en una variable la mejor posición alcanzada por el enjambre de partículas en su conjunto, a esta variable se la denomina *gbest* (“global best”) (ver Figura 2).

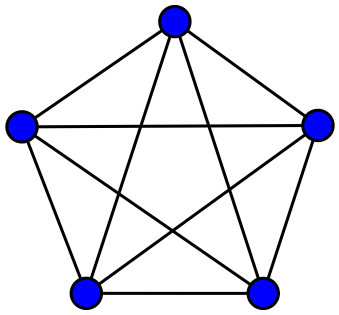


Figura 2: Grafo completo. *Wikipedia*.

b) **Topología *lbest***: En esta topología cada individuo se encuentra conectado a $K = 2$ otros individuos formando un anillo. Esta topología tiene la ventaja que cada una de las subpoblaciones puede buscar de forma paralela aumentando la capacidad de exploración del algoritmo aunque converge de manera más lenta que *gbest*.

2. **Topologías dinámicas:**

   a) **K-vecinos más cercanos:** En este caso una partícula tan solo puede obtener información sobre la mejor posición obtenida por los K-vecinos más cercanos.

   b) **Ponderación por la distancia Euclídea:** En este caso cada partícula se ve afectada por la mejor posición global encontrada ponderada por la distancia Euclídea entre las partículas.

En nuestro caso usaremos la topología usada canónicamente en PSO, *gbest* [33], tal y como se observa en la Figura 3.

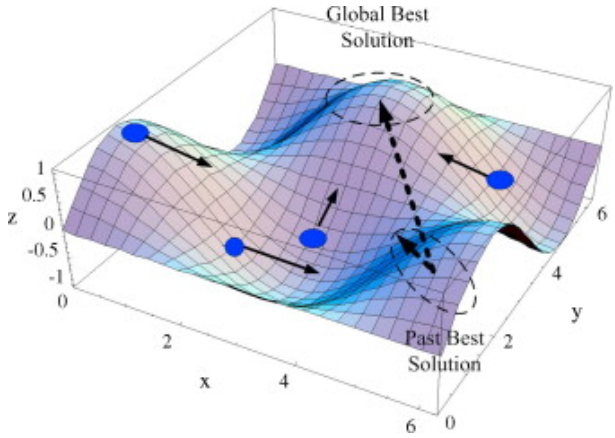


Figura 3: Representación del funcionamiento de PSO con topología $gbest$.

3.3.1. Principales parámetros

Daremos a continuación algunos de los principales parámetros de la versión original del algoritmo [23] que será el que implementemos:

Cuadro 3: Principales Parámetros de la Optimización por Enjambre de Partículas (PSO)

Parámetro	**Símbolo**	**Valores Típicos**
Tamaño de la Población	N	100
Coeficiente de Mejor Personal	ϕ_1	1.5 - 2.0
Coeficiente de Mejor Global	ϕ_2	1.5 - 2.0
Limitación de Velocidad	V_{max}	Específico del problema

- **Tamaño de la Población**: Número de partículas en el enjambre. Determina el grado de exploración en el espacio de búsqueda.

- **Coeficiente de Mejor Personal (ϕ_1)**: Coeficiente que escala la atracción hacia la mejor posición de la propia partícula. Fomenta la búsqueda local.

- **Coeficiente de Mejor Global (ϕ_2)**: Coeficiente que escala la atracción hacia la mejor posición global del enjambre. Fomenta la búsqueda global.

- **Limitación de Velocidad (V_{max})**: Limita la velocidad máxima que puede alcanzar una partícula para evitar saltos excesivamente grandes. En la implementación concreta que usaremos, limita la velocidad máxima que se puede alcanzar en cada componente del vector de velocidad. Su valor dependerá del problema pero un valor sensato es el diámetro de la región que se desee explorar en el problema en el caso de que este se encuentre acotado.

3.3.2. Flujo algorítmico

A continuación se ofrece pseudocódigo describiendo el flujo algorítmico de la implementación de PSO que se usará:

Algorithm 4 Algoritmo PSO Original

Inicialización:
Crear una población de partículas con posiciones y velocidades aleatorias en un espacio de búsqueda de N dimensiones.
Establecer la mejor posición personal ($\mathbf{pbest}_i$) de cada partícula a su posición inicial.
Establecer la mejor posición global (**gbest**) encontrada por el enjambre.
Establecemos en $ngen$ el número de iteraciones a ejectutar.
$gen \leftarrow 0$
while $gen \leq ngen$ **do**
    for cada partícula i en la población **do**
        Evaluar la función de aptitud en la posición actual $\mathbf{x}^i$.
        if la aptitud actual es mejor que la aptitud de $\mathbf{pbest}^i$ **then**
            Actualizar $\mathbf{pbest}^i$ con la posición actual $\mathbf{x}^i$.
        end if
        if la aptitud actual de $\mathbf{pbest}^i$ es mejor que la aptitud de **gbest then**
            Actualizar **gbest** con $\mathbf{pbest}_i$.
        end if
        Actualizar la velocidad de la partícula i, $\mathbf{v}^i$, usando:

$$\mathbf{v}^i \leftarrow \mathbf{v}^i + \phi_1 r_1(\mathbf{pbest}^i - \mathbf{x}^i) + \phi_2 r_2(\mathbf{gbest} - \mathbf{x}^i)$$

        for cada componente j de la velocidad v^i_j **do**
            if $|\mathbf{v}^i_j| > V_{max}$ **then**

$$v^i_j \leftarrow signo(v^i_j) \cdot V_{max}$$

            end if
        end for
        Actualizar la posición de la partícula i, $\mathbf{x}^i$:

$$\mathbf{x}^i \leftarrow \mathbf{x}^i + \mathbf{v}^i$$

    end for
    $gen \leftarrow gen + 1$
end while

4

Desarrollo experimental

4.1. Conjunto de datos

El conjunto de datos utilizado para el estudio está compuesto por ocho pares de tablas, cada una agrupando datos sobre 10 empresas seleccionadas aleatoriamente. Para la creación de estos conjuntos de datos, se partió de una base original que incluía 250 empresas de diversos países y bolsas de valores. Cada empresa está identificada por su nombre, ubicación y sector de la industria, además de su ticker bursátil, que sirve como vínculo con la tabla de retornos. En esta base de datos, se recopilaron los precios de cierre diarios de cada acción durante el año 2022, rellenando los días sin cotización (debido al cierre de la bolsa en ciertos países) para asegurar que cada empresa tuviera precios disponibles para todos los días en que otras empresas también cotizaban. Además de los precios de cierre, se incluyeron los datos de sostenibilidad del año 2023, los cuales reflejan la evaluación de 2022 según las siguientes agencias de calificación ESG: S&P Global ESG, RobecoSAM ESG, ISS ESG, MSCI ESG, y Sustainalytics ESG Risk.

Para cada uno de los ocho escenarios de comparación, se eligieron al azar 10 empresas, con reemplazo, siguiendo el criterio de diversificación que exige al menos tres empresas de diferentes bolsas y al menos cuatro sectores industriales distintos. Esta estrategia permite evaluar la capacidad del algoritmo para optimizar tanto la selección de pesos en la cartera como el modelo de sostenibilidad en un entorno diverso.

A continuación, se detallan los campos relevantes para el análisis en las primeras filas de ambas tablas del conjunto de datos 0:

TICKER	2022-01-04	2022-01-05	2022-01-06	2022-01-07	2022-01-10
CNR.TO	0.00000000	-0.01007165	0.01630470	0.00173268	-0.00474059
GALP.LS	0.05131740	0.01351052	-0.00129005	0.00645860	0.00898392
8802.T	0.00000000	0.02118380	-0.01098231	-0.00616903	0.00675047
1972.HK	-0.00742582	0.01745638	-0.02058824	0.01351354	0.00493829
KBANK.BK	0.00000000	0.00343643	-0.02397260	0.00000000	0.00350877
HINDALCO.BO	-0.00397571	-0.00168065	0.00820706	0.02922146	-0.00101399
2897.T	0.00000000	0.00472810	-0.00588230	0.00118340	-0.01684395
4528.T	0.00000000	-0.01317898	-0.01245263	0.00091374	0.01602154
HES	0.05690849	-0.00406606	0.05468264	0.01607041	-0.01697069
SW.PA	0.03462527	0.01223782	0.00394763	-0.01646591	0.00774609

Cuadro 4: Ejemplo de la tabla de retornos del grupo 0 del conjunto de datos.

TICKER	S&P-ESG	R-ESG	ISS-ESG-AR	MSCI-ESG-AR	SUST-ESG RISK*-AR
CNR.TO	81	74	58.33	85.71	72.00
GALP.LS	82	74	58.33	100.00	50.60
8802.T	72	72	33.33	71.43	66.20
1972.HK	83	68	50.00	100.00	78.40
KBANK.BK	86	68	25.00	85.71	58.20
HINDALCO.BO	83	82	41.67	57.14	36.80
2897.T	80	66	33.33	71.43	45.40
4528.T	79	74	50.00	85.71	48.60
HES	72	81	50.00	100.00	33.80
SW.PA	69	79	33.33	57.14	55.20

Cuadro 5: Ejemplo de la tabla de calificaciones ESG del grupo 0 del conjunto de datos.

4.2. Frontera de Pareto

Consideremos el siguiente problema multiobjetivo:

$$min\ [(\mathbf{w}^p)'\mathbf{\Sigma}\mathbf{w}^p, -(\mathbf{w}^p)'\boldsymbol{\mu}, -(\mathbf{w}^p)'\mathbf{S}'\mathbf{w}^s] \tag{9}$$

$$\begin{aligned} \text{s.a.} \quad & \mathbf{1}'\mathbf{w}^p = 1 \\ & \mathbf{1}'\mathbf{w}^s = 1 \\ & \mathbf{w}^p \geq \mathbf{0} \\ & \mathbf{w}^s \geq \mathbf{0} \end{aligned}$$

donde $\mathbf{\Sigma} \in \mathbb{R}^{N\times N}$ es la matriz de riesgo, $\boldsymbol{\mu} \in \mathbb{R}^N$ es el vector de rendimientos medios, $\mathbf{S} \in \mathbb{R}^{D\times N}$ es la matriz de calificación ESG, N es el número de activos y D el número de

agencias de calificación ESG.

Haciendo uso del algoritmo NSGA-II y usando la clase *ParetoFront* que ofrece la biblioteca *Deap* podemos mantener un registro de todas aquellas soluciones que no se encuentran dominadas.

Observemos que la superficie obtenida es aquella que obtendríamos de representar aquellas carteras que fueran solución del problema de optimización expuesto en la sección 2.6 para cada par de valores reales no negativos de $(\lambda_\sigma, \lambda_{ESG})$ en el espacio de Media-Varianza-ESG.

A continuación representamos dicha frontera de Pareto para los conjuntos de activos 1, 5 y 7.

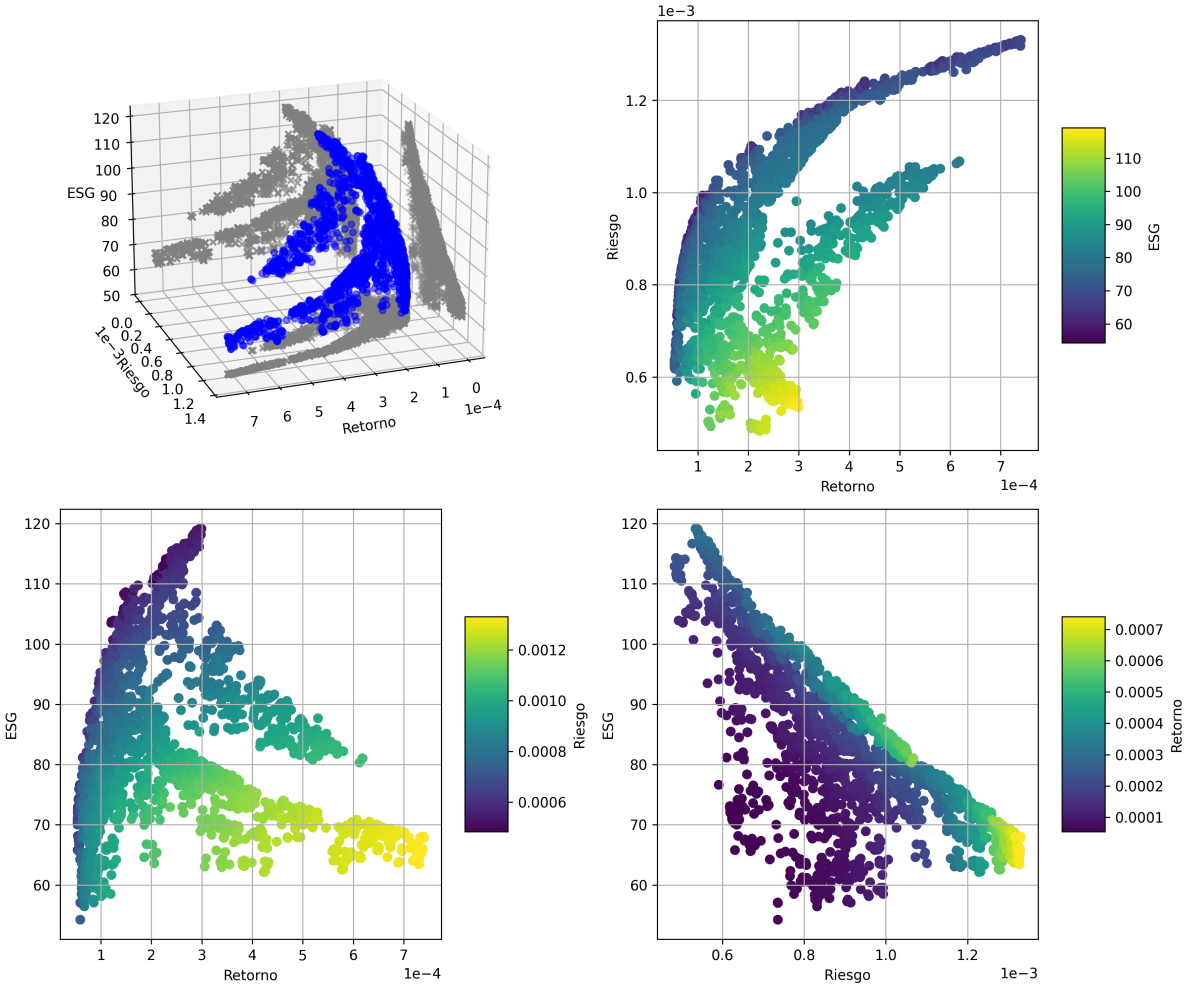


Figura 4: Frente de Pareto del conjunto de activos 1.

En la gráfica superior izquierda encontramos representada la superficie de Pareto, cada

punto representa una cartera de inversión en la que para mejorar en cualquiera de los objetivos forzosamente debe de empeorar en los otros.

En la gráfica en la que presentamos el riesgo en función del retorno podemos observar una clara frontera convexa, típica de la frontera eficiente de Markowitz. Las carteras con mayor retorno generalmente presentan un mayor riesgo y tienden a ubicarse en la parte superior derecha del gráfico. La coloración revela que las carteras con calificaciones ESG más altas se concentran en la región de menor riesgo y menor retorno, sugiriendo cierta relación entre sostenibilidad y retorno, al menos a mismos niveles de riesgo.

En la gráfica en la que representamos la calificación ESG en función del retorno podemos observar que las carteras con mayores calificaciones ESG tienden a concentrarse en la región de menor retorno y menor riesgo (tonalidades más oscuras). A medida que aumenta el retorno, se observa una disminución en la calificación ESG y un incremento en el riesgo.

Finalmente, en la gráfica en la que representamos la calificación ESG en función del riesgo podemos observar como a medida que aumenta el riesgo, la calificación ESG disminuye y el retorno tiende a aumentar.

Un análisis similar puede hacerse del resto de gráficas.

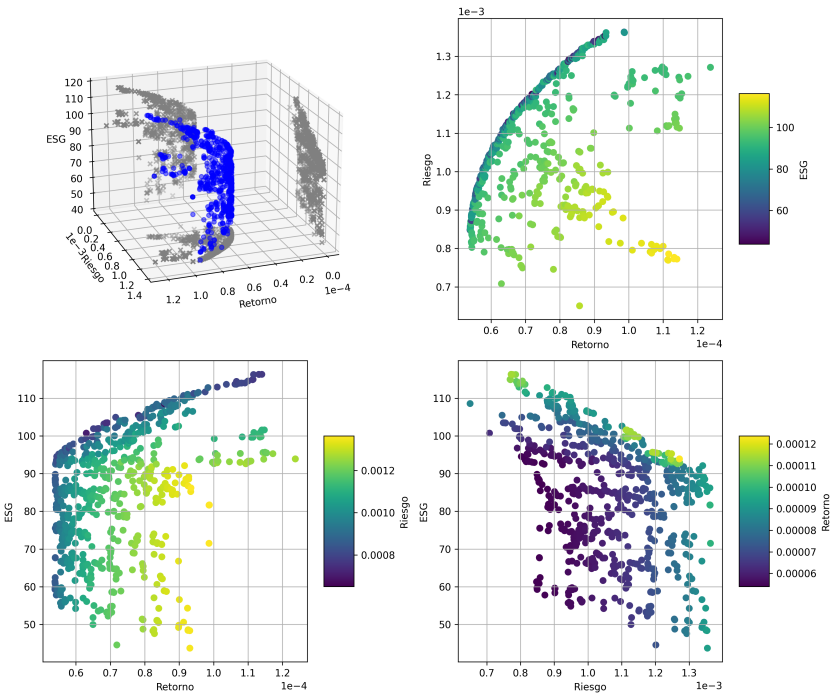


Figura 5: Frente de Pareto del conjunto de activos 5.

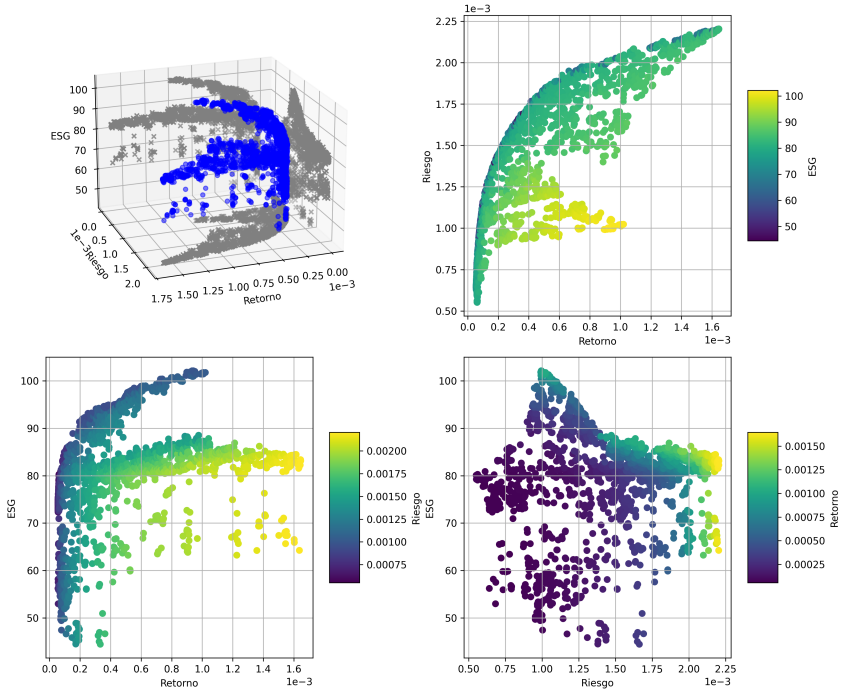


Figura 6: Frente de Pareto del conjunto de activos 7.

4.3. Implementación del modelo multiagencia en dos etapas

Recordemos el problema de optimización descrito en 2.7 y buscaremos implementarlo usando los algoritmos evolutivos descritos en el trabajo.

En primer lugar deberemos de optimizar el Índice de Sharpe:

$$\begin{aligned} \max_{\mathbf{w}^p \in \mathbb{R}^N} \quad & \frac{\left((\mathbf{w}^p)'\boldsymbol{\mu}\right)^2}{(\mathbf{w}^p)'\boldsymbol{\Sigma}\mathbf{w}^p} \\ \text{s. a.} \quad & \mathbf{1}_N'\mathbf{w}^p = 1. \\ & \mathbf{w}^p \geq \mathbf{0}_N, \end{aligned}$$

Haremos uso de las restricciones para modificar el espacio de búsqueda:

$$\mathbf{1}_N'\mathbf{w}^p = 1 \tag{10}$$

$$\mathbf{w}^p \geq \mathbf{0}_N \tag{11}$$

Observemos que la restricción 10 nos indica que las soluciones se encuentran en un hiperplano mientras que la restricción 11 nos indica que se encuentran en el primer octante. Podemos

parametrizar el espacio de búsqueda $B = \{\mathbf{x} \in \mathbb{R}^N \mid \mathbf{1}'_N \mathbf{w}^p = 1,\ \mathbf{w}^p \geq \mathbf{0}_N\}$ definido por dichas restricciones como la gráfica de la siguiente función:

$$\varphi : B' \longrightarrow \mathbb{R}$$
$$\varphi(x_1, \ldots, x_{N-1}) = 1 - x_1 - \ldots - x_{N-1}$$

donde $B' = \{\mathbf{x} \mid \|\mathbf{x}\|_1 \leq 1,\ \mathbf{x} \geq \mathbf{0}_{N-1}\} \subset \mathbb{R}^{N-1}$, siendo $\|\cdot\|_1$ la norma-1 dada por $\|y\|_1 = |y_1| + |y_2| + \ldots + |y_n|$ si $y \in \mathbb{R}^n$.

De manera que:

$$\mathbf{w}^p = (w_1^p, \ldots, w_{N-1}^p, \varphi(w_1^p, \ldots, w_{N-1}^p))'$$

Consideremos:

$$\Phi : B' \longrightarrow \mathbb{R}^N$$
$$\Phi(w_1^p, \ldots, w_{N-1}^p) = (w_1^p, \ldots, w_{N-1}^p, \varphi(w_1^p, \ldots, w_{N-1}^p))' = \mathbf{w}^p$$

El correspondiente código de implementación quedaría definido como:

```
1    def map_from_auxiliary_coordinates(x):
2        z = 1 - np.sum(x)
3        return np.append(x, z)
4
```

Figura 7: Implementación de Φ con el nombre *map_from_auxiliary_coordinates*.

Con esto tenemos que Φ parametriza B a través de B'.

También usaremos:

$$\Pi_n : \mathbb{R}^n \longrightarrow \mathbb{R}^{n-1}$$
$$\Pi_n(\mathbf{x}) = (x_1, \ldots, x_{n-1})'$$

En concreto observemos que si $\mathbf{w}^p \in B$ entonces $\Pi_N(\mathbf{w}^p) \in B'$ y de manera simétrica si $\overline{\mathbf{w}}^p \in B'$ entonces $\Phi(\overline{\mathbf{w}}^p) \in B$. Por simplicidad, en adelante usaremos $\overline{\mathbf{w}}^p$ para hacer referencia a $\Pi_N(\mathbf{w}^p)$.

Considerar esta parametrización nos permitirá imponer las restricciones mediante el método de las penalizaciones de forma efectiva y precisa, puesto que el conjunto B' es un conjunto con interior en el espacio ambiente $\mathbb{R}^{N-1}$ mientras que B no posee interior en el espacio ambiente $\mathbb{R}^N$, esto haría que la naturaleza estocástica de los algoritmos evolutivos penalizara casi seguro (al menos si no tenemos en cuenta que trabajamos con aritmética de punto flotante) a los individuos si trabajásemos en con el espacio de búsqueda B.

Definamos la función de penalización p:

$$
\begin{aligned}
&p : B' \longrightarrow \mathbb{R} \\
&p(\overline{\mathbf{w}}^p) = K \left[\text{máx } \{0, \|\overline{\mathbf{w}}^p\|_1 - 1\} - \sum_{i=1}^{N-1} \text{mín}\{0, \overline{w}_i^p\} \right]
\end{aligned}
$$

donde $K \in \mathbb{R}^+$ es un coeficiente de penalización. El código quedaría como:

```
def penalization(w):
    norm = np.linalg.norm(w, 1)
    penalization = 0
    if norm > 1:
        penalization += penalization_weight * norm
    for x in w:
        if x < 0:
            penalization += penalization_weight * (-x)
    return penalization

```

Figura 8: Implementación de la función de penalización.

Finalmente podemos expresar al individuo $\mathbf{x}$ como:

$$
\mathbf{x} = (w_1^p, \ldots, w_{N-1}^p) = \Pi_n(\mathbf{w}^p) = \overline{\mathbf{w}}^P \in \mathbb{R}^{N-1}
$$

Y tomaremos la función de aptitud f:

$$
\begin{aligned}
f(\mathbf{x}) &= \frac{(\Phi(\mathbf{x}))'\boldsymbol{\mu}}{\sqrt{\Phi(\mathbf{x})'\boldsymbol{\Sigma}\Phi(\mathbf{x})}} - p(\mathbf{x}) = \\
&= \frac{(\mathbf{w}^p)'\boldsymbol{\mu}}{\sqrt{\mathbf{w}^p)'\boldsymbol{\Sigma}\mathbf{w}^p}} - p(\overline{\mathbf{w}}^p)
\end{aligned}
$$

cuyo código quedaría definido como:

```
    def evaluate(ind):
        w = ind
        p = penalization(w)
        w = map_from_auxiliary_coordinates(w)
        w = np.atleast_2d(w).T
        res = (w.T@mu / (w.T@sigma@w)**0.5)[0]
        return res - p

```

Figura 9: Implementación de la función de aptitud.

Tenemos entonces que siendo $\mathbf{x}^*$ el individuo óptimo encontrado, se puede calcular el vector de pesos de los activos que maximiza el ratio de Sharpe como sigue:

$$\mathbf{w}^p = \Phi(\mathbf{x}^*)$$

Una vez fijado $\mathbf{w}^p$, optimizamos el vector de pesos de las agencias de calificación ESG, $\mathbf{w}^s$, para maximizar la sostenibilidad de la cartera como se detalla en la sección 2.7.

$$w_d^s = \begin{cases} 1 & \text{si } d = \arg\max_d((\mathbf{w}^p)'\mathbf{S}')_d \\ 0 & \text{en otro caso} \end{cases}$$

```
    index_max = np.argmax(w_p.T@esg)
    w_s = np.zeros(m)
    w_s[index_max] = 1

```

Figura 10: Optimización del vector de pesos de las agencias de calificación ESG.

4.4. Comparativa del modelo multiagencia en dos etapas

Realizaremos una comparación de los resultados obtenidos de la cartera construida con este modelo usando los algoritmos CMA-ES, NSGA-II y PSO con otros métodos de construcción de carteras usando distintas métricas.

4.4.1. Carteras de inversión a comparar

A continuación detallaremos alguna de las carteras ampliamente estudiadas en la literatura que usaremos en la comparación. Aquellas que no tengan en consideración los criterios ambientales, tras fijar el vector de pesos de los activos, $\mathbf{w}^p$, se optimizará el vector de pesos de las agencias de calificación ESG como se expone en el caso del modelo multiagencia en dos etapas presentado.

- ***Equally Weighted* (EW):**

  Para construir esta cartera de inversión simplemente tomaremos $\mathbf{w}^p = \frac{1}{N}\mathbf{1}_N$ y optimizamos $\mathbf{w}^s$ para maximizar la calificación ESG de la cartera.

- ***Global Maximum Return* (GMR):**

  Para construir esta cartera de inversión en primer lugar resolveremos el siguiente problema de optimización en el que obtendremos la cartera $\mathbf{w}^p$ que maximiza el retorno medio:

$$\begin{aligned} \max_{\mathbf{w}^p \in \mathbb{R}^N} \quad & (\mathbf{w}^p)' \boldsymbol{\mu} \\ \text{s. a.} \quad & \mathbf{1}_N' \mathbf{w}^p = 1. \\ & \mathbf{w}^p \geq \mathbf{0}_N, \end{aligned}$$

  Este es un problema de optimización lineal que cuenta con fácil solución:

$$w_i^p = \begin{cases} 1 & \text{si } i = \arg\max_i \mu_i \\ 0 & \text{en otro caso} \end{cases}$$

  Una vez encontrado el óptimo $\mathbf{w}^p$, encontraremos el vector $\mathbf{w}^s$ que maximiza la evaluación ESG.

```python
import numpy as np

def maxReturn(sigma, mu, esg):
    (n, m) = esg.shape

    w_p = np.zeros(n)
    w_s = np.zeros(m)

    max_return_index = np.argmax(mu)
    w_p[max_return_index] = 1

    max_esg_index = np.argmax(w_p@esg)
    w_s[max_esg_index] = 1

    return w_p, w_s

```

Figura 11: Cartera GMR.

- ***Global Minimum Variance* (GMV):**

  Para construir esta cartera de inversión consideraremos en primer lugar resolveremos el siguiente problema de optimización en el que obtendremos la cartera $\mathbf{w}^p$ que minimiza el riesgo:

$$\begin{aligned} \min_{\mathbf{w}^p \in \mathbb{R}^N} \quad & (\mathbf{w}^p)' \boldsymbol{\Sigma} \mathbf{w}^p \\ \text{s. a.} \quad & \mathbf{1}_N' \mathbf{w}^p = 1. \\ & \mathbf{w}^p \geq \mathbf{0}_N, \end{aligned}$$

  Una vez encontrado el óptimo $\mathbf{w}^p$, encontraremos el vector $\mathbf{w}^s$ que maximiza la evaluación ESG.

  Podemos encontrar $\mathbf{w}^p$ en forma cerrada con la fórmula:

$$\mathbf{w}^p = \frac{\boldsymbol{\Sigma}^{-1}\mathbf{1}}{\mathbf{1}^\top \boldsymbol{\Sigma}^{-1}\mathbf{1}}$$

  No obstante, se ha utilizado la biblioteca *cvxpy* para obtener la solución del problema cuadrático, en lugar de emplear la fórmula de solución cerrada tradicionalmente utilizada. Esta elección se debe a que los errores inherentes a la aritmética de punto flotante pueden provocar que las soluciones obtenidas mediante la fórmula cerrada no sean factibles, es decir, no satisfagan las restricciones del problema de manera adecuada. Con la

biblioteca se han obtenido resultados más robustos y confiables en el sentido de que las soluciones aportadas por la fórmula cerrada distaban considerablemente de ser soluciones factibles.

```
import numpy as np
import cvxpy as cp

def minRisk(sigma, mu, esg):
    (n, m) = esg.shape
    w_s = np.zeros(m)

    x = cp.Variable(n)
    min_risk = cp.Minimize(cp.QuadForm(x, sigma))
    constraints = [cp.sum(x) == 1, x >= 0]
    problem = cp.Problem(min_risk, constraints)
    problem.solve()

    w_p = x.value

    max_esg_index = np.argmax(w_p@esg)
    w_s[max_esg_index] = 1

    return w_p, w_s

```

Figura 12: Cartera GMV usando la biblioteca *cvxpy*.

- ***Maximum Diversification*** **(MD):**

  Para construir esta cartera consideramos el vector de desviaciones típicas de los activos, $\boldsymbol{\sigma}$, y definimos el ratio de diversificación de una cartera $\mathbf{w}^p$ como sigue:

$$DR(\mathbf{w}^p) = \frac{(\mathbf{w}^p)'\boldsymbol{\sigma}}{\sqrt{(\mathbf{w}^p)'\boldsymbol{\Sigma}\mathbf{w}}}$$

  Maximizaremos dicho ratio:

$$\begin{aligned} \max_{\mathbf{w}^p \in \mathbb{R}^N} \quad & \frac{((\mathbf{w}^p)'\boldsymbol{\sigma})^2}{(\mathbf{w}^p)'\boldsymbol{\Sigma}\mathbf{w}^p} \\ \text{s. a.} \quad & \mathbf{1}_N'\mathbf{w}^p = 1. \\ & \mathbf{w}^p \geq \mathbf{0}_N, \end{aligned}$$

  Para resolver este problema de optimización usaremos el algoritmo CMA-ES de manera completamente análoga a como hemos optimizado el ratio de Sharpe.

Una vez encontrado $\mathbf{w}^p$ óptimo, encontraremos el vector $\mathbf{w}^s$ que maximiza la evaluación ESG.

- ***Maximum Sustainability* (MS):**

  Para construir esta cartera resolveremos el siguiente problema de optimización:

$$\begin{aligned} \max_{\substack{\mathbf{w}^p \in \mathbb{R}^N \\ \mathbf{w}^s \in \mathbb{R}^D}} \quad & (\mathbf{w}^p)' \mathbf{S}' \mathbf{w}^s \\ \text{s.a.} \quad & \mathbf{1}' \mathbf{w}^p = 1 \\ & \mathbf{1}' \mathbf{w}^s = 1 \\ & \mathbf{w}^p \geq \mathbf{0} \\ & \mathbf{w}^s \geq \mathbf{0} \end{aligned}$$

  La solución de este problema viene dada por:

$$w_i^p = \begin{cases} 1 & \text{si } (i,j) = \arg\max_{(i,j)} S_{ij} \\ 0 & \text{en otro caso} \end{cases}$$

$$w_j^s = \begin{cases} 1 & \text{si } (i,j) = \arg\max_{(i,j)} S_{ij} \\ 0 & \text{en otro caso} \end{cases}$$

4.4.2. Comparativa

A continuación se presenta una tabla que resume el rendimiento de diversas estrategias en términos de las métricas de índice de Sharpe, retorno, riesgo y puntuación ESG. Esta tabla proporciona una visión detallada de cómo cada estrategia se desempeña en función de estas métricas clave, que son fundamentales para evaluar el desempeño financiero y la sostenibilidad de las carteras. Al analizar los datos, se observa que la metodología propuesta en este TFG destaca por lograr un equilibrio óptimo entre el índice de Sharpe, que ya incorpora tanto el retorno como el riesgo, y la puntuación ESG. Específicamente, la metodología basada en los algoritmos CMA, NSGA-II y PSO ofrece un notable *trade-off*, logrando índices de Sharpe elevados mientras mantienen puntuaciones ESG competitivas. Este rendimiento superior

sugiere que la propuesta metodológica expuesta en este trabajo no solo maximiza el retorno ajustado por riesgo, sino que también integra de manera efectiva criterios de sostenibilidad, consolidándose como una estrategia robusta en la optimización de carteras.

Sharpe	Retorno	Riesgo	ESG	Grupo	Estrategia
0.09139103	0.00075558	0.00006835	81.42700000	0	EW
0.09970457	0.00275080	0.00076118	100.00000000	0	GMR
0.06640906	0.00041754	0.00003953	83.11312189	0	GMV
0.07184615	0.00170014	0.00055997	100.00000000	0	MS
0.10019525	0.00086421	0.00007440	78.22567491	0	MD
0.12874014	0.00137592	0.00011422	80.53558137	0	MV(ESG)$_{CMA}$
0.12881873	0.00139710	0.00011762	80.75414155	0	MV(ESG)$_{NSGA-II}$
0.12869915	0.00139159	0.00011692	81.25801282	0	MV(ESG)$_{PSO}$
0.08268695	0.00073870	0.00007981	79.80000000	1	EW
0.04076941	0.00143638	0.00124128	75.00000000	1	GMR
0.08701621	0.00063749	0.00005367	81.03079260	1	GMV
0.03049867	0.00053278	0.00030516	100.00000000	1	MS
0.07282564	0.00082510	0.00012836	79.72453485	1	MD
0.10244842	0.00086388	0.00007111	79.40167023	1	MV(ESG)$_{CMA}$
0.10245033	0.00086344	0.00007103	79.42408921	1	MV(ESG)$_{NSGA-II}$
0.10244035	0.00086325	0.00007101	79.40810893	1	MV(ESG)$_{PSO}$
0.03314620	0.00034384	0.00010761	84.28400000	2	EW
0.06986986	0.00082636	0.00013988	100.00000000	2	GMR
0.07635637	0.00056602	0.00005495	88.22615943	2	GMV
0.06986986	0.00082636	0.00013988	100.00000000	2	MS
0.03461773	0.00033952	0.00009619	85.16158255	2	MD
0.08575121	0.00067984	0.00006285	91.01598934	2	MV(ESG)$_{CMA}$
0.08648961	0.00068088	0.00006198	91.23939371	2	MV(ESG)$_{NSGA-II}$
0.08593479	0.00067242	0.00006123	90.62498359	2	MV(ESG)$_{PSO}$
0.10301664	0.00096926	0.00008852	81.10000000	3	EW
0.09075450	0.00355061	0.00153062	91.00000000	3	GMR
0.05501924	0.00039764	0.00005223	81.36230202	3	GMV
0.08659310	0.00198836	0.00052726	100.00000000	3	MS
0.12597783	0.00148632	0.00013920	81.90171948	3	MD
0.15500523	0.00191398	0.00015247	88.54534037	3	MV(ESG)$_{CMA}$
0.15524449	0.00192806	0.00015424	88.64769171	3	MV(ESG)$_{NSGA-II}$
0.15465808	0.00185169	0.00014335	88.29702794	3	MV(ESG)$_{PSO}$

Cuadro 6: **Parte 1**. Datos de rendimiento, riesgo, y puntuación ESG por estrategia y grupo.

Sharpe	Retorno	Riesgo	ESG	Grupo	Estrategia
0.08041482	0.00071936	0.00008002	84.28300000	4	EW
0.08559209	0.00197947	0.00053485	88.00000000	4	GMR
0.09217922	0.00065135	0.00004993	84.84410992	4	GMV
0.04723495	0.00071021	0.00022607	100.00000000	4	MS
0.09882812	0.00091587	0.00008588	86.92009230	4	MD
0.13804401	0.00121045	0.00007689	85.57727667	4	MV(ESG)$_{CMA}$
0.13843504	0.00117755	0.00007235	85.89970070	4	MV(ESG)$_{NSGA-II}$
0.13789894	0.00117776	0.00007294	86.00094287	4	MV(ESG)$_{PSO}$
0.07990547	0.00066270	0.00006878	88.57100000	5	EW
0.07984897	0.00144920	0.00032940	75.00000000	5	GMR
0.11220809	0.00082231	0.00005371	93.25048988	5	GMV
0.12263581	0.00137382	0.00012549	100.00000000	5	MS
0.08932185	0.00080419	0.00008106	86.60528392	5	MD
0.14290501	0.00125304	0.00007688	92.28740706	5	MV(ESG)$_{CMA}$
0.14301688	0.00126927	0.00007876	92.37206105	5	MV(ESG)$_{NSGA-II}$
0.14269352	0.00121910	0.00007299	92.17693486	5	MV(ESG)$_{PSO}$
0.06307195	0.00055669	0.00007790	81.00000000	6	EW
0.07929689	0.00191699	0.00058442	84.00000000	6	GMR
0.05192251	0.00040045	0.00005948	78.79709701	6	GMV
0.01621619	0.00031836	0.00038543	100.00000000	6	MS
0.06516518	0.00058993	0.00008195	81.93639248	6	MD
0.10193717	0.00114662	0.00012652	79.71618858	6	MV(ESG)$_{CMA}$
0.10215268	0.00115411	0.00012764	79.64873393	6	MV(ESG)$_{NSGA-II}$
0.10172869	0.00114248	0.00012613	79.42312792	6	MV(ESG)$_{PSO}$
0.08482624	0.00088783	0.00010955	80.10000000	7	EW
0.05404313	0.00221676	0.00168251	86.00000000	7	GMR
0.08227228	0.00061281	0.00005548	78.45223470	7	GMV
0.03028648	0.00100567	0.00110259	91.00000000	7	MS
0.08820725	0.00100990	0.00013108	79.48711664	7	MD
0.11692012	0.00115153	0.00009700	82.73590059	7	MV(ESG)$_{CMA}$
0.11699834	0.00115997	0.00009829	82.75279460	7	MV(ESG)$_{NSGA-II}$
0.11693196	0.00115115	0.00009692	82.71533088	7	MV(ESG)$_{PSO}$

Cuadro 7: **Parte 2**. Datos de rendimiento, riesgo, y puntuación ESG por estrategia y grupo.

5

Conclusiones y Líneas Futuras

5.1. Conclusiones

La metodología propuesta en este Trabajo de Fin de Grado se consolida como una estrategia integral y efectiva para la optimización de carteras, logrando un balance destacado entre el rendimiento financiero y la sostenibilidad. La integración de varias agencias de calificación en materia ambiental conseguida por la estrategia planteada permite ignorar el problema de divergencia entre dichas agencias y a la par aumentar la correlación entre los criterios financieros y de sostenibilidad reforzando la idea de que la integración de criterios ESG no debe ser vista como una concesión en términos de retorno, sino como una oportunidad para mejorar la calidad de la inversión a largo plazo.

Además, el uso de algoritmos basados en poblaciones, como CMA-ES, NSGA-II y PSO, juega un papel crucial en la optimización eficiente de este problema complejo, erigiendo estos algoritmos como métodos efectivos y eficientes para identificar configuraciones óptimas de carteras, lo que sería difícil de lograr con métodos tradicionales. En este trabajo se ha explorado la capacidad de estos algoritmos para manejar múltiples objetivos y su adaptabilidad a diferentes escenarios de mercado, mostrándose como herramientas poderosas para abordar la optimización de carteras.

5.2. Líneas Futuras

En futuros desarrollos del presente TFG, se puedrían explorar diversas áreas para mejorar y ampliar el modelo multiagencia basado en Markowitz y su implementación mediante algoritmos basados en poblaciones. Una posible línea de investigación es la integración de técni-

cas avanzadas de aprendizaje automático para identificar patrones en los datos de retornos y ESG. Esto permitiría ajustar dinámicamente los parámetros del modelo y mejorar su capacidad predictiva. Además, se podría ampliar el modelo para incluir simulaciones de escenarios de mercado adversos y análisis de sensibilidad, lo que ayudaría a evaluar el comportamiento del modelo en condiciones económicas extremas. Estas mejoras facilitarían una comprensión más profunda de la robustez del modelo y su adaptabilidad a diferentes contextos de mercado y políticas de sostenibilidad.

Referencias

[1] Konstantinos P Anagnostopoulos y Georgios Mamanis. "A portfolio optimization model with three objectives and discrete variables". En: *Computers & Operations Research* 37.7 (2010), págs. 1285-1297.

[2] Jarosław Arabas y Dariusz Jagodziński. "Toward a matrix-free covariance matrix adaptation evolution strategy". En: *IEEE Transactions on Evolutionary Computation* 24.1 (2019), págs. 84-98.

[3] Florian Berg, Julian F Koelbel y Roberto Rigobon. "Aggregate confusion: The divergence of ESG ratings". En: *Review of Finance* 26.6 (2022), págs. 1315-1344.

[4] Hans-Georg Beyer y Bernhard Sendhoff. "Simplify your covariance matrix adaptation evolution strategy". En: *IEEE Transactions on Evolutionary Computation* 21.5 (2017), págs. 746-759.

[5] Taras Bodnar, Nestor Parolya y Wolfgang Schmid. "Estimation of the global minimum variance portfolio in high dimensions". En: *European Journal of Operational Research* 266.1 (2018), págs. 371-390.

[6] Nicolas PB Bollen. "Mutual fund attributes and investor behavior". En: *Journal of financial and quantitative analysis* 42.3 (2007), págs. 683-708.

[7] Shi Cheng et al. "Survey on data science with population-based algorithms". En: *Big Data Analytics* 1 (2016), págs. 1-20.

[8] Kalyanmoy Deb et al. "A Fast Elitist Non-dominated Sorting Genetic Algorithm for Multi-objective Optimization: NSGA-II". En: *Parallel Problem Solving from Nature PPSN VI*. Ed. por Marc Schoenauer et al. Berlin, Heidelberg: Springer, 2000, págs. 849-858. ISBN: 978-3-540-45356-7.

[9] Kalyanmoy Deb et al. "A fast elitist non-dominated sorting genetic algorithm for multi-objective optimization: NSGA-II". En: *Parallel Problem Solving from Nature PPSN VI: 6th International Conference Paris, France, September 18–20, 2000 Proceedings 6*. Springer. 2000, págs. 849-858.

[10] Werner Dinkelbach. "On Nonlinear Fractional Programming". En: *Management Science* (mar. de 1967). Publisher: INFORMS.

[11] D. C. Dracopoulos y S. Kent. “Genetic programming for prediction and control”. en. En: *Neural Computing & Applications* 6.4 (dic. de 1997), págs. 214-228. ISSN: 1433-3058.

[12] Francisco Fernández-Navarro et al. “Mean Squared Variance Portfolio: A Mixed-Integer Linear Programming Formulation”. En: *Mathematics* 9.3 (2021), pág. 223. ISSN: 2227-7390.

[13] David B. Fogel. “Artificial Intelligence through Simulated Evolution”. En: *Evolutionary Computation: The Fossil Record*. Conference Name: Evolutionary Computation: The Fossil Record. IEEE, 1998, págs. 227-296. ISBN: 978-0-470-54460-0. (Visitado 09-09-2024).

[14] A. Garcia-Bernabeu et al. “Computing the Mean-Variance-Sustainability Nondominated Surface by ev-MOGA”. en. En: *Complexity* 2019 (dic. de 2019), págs. 1-12. ISSN: 1076-2787, 1099-0526. (Visitado 21-02-2024).

[15] Ana Garcia-Bernabeu et al. “Computing the mean-variance-sustainability nondominated surface by Ev-MOGA”. En: *Complexity* 2019 (2019), págs. 1-12.

[16] A. Hanif Halim, I. Ismail y Swagatam Das. “Performance assessment of the metaheuristic optimization algorithms: an exhaustive review”. en. En: *Artificial Intelligence Review* 54.3 (mar. de 2021), págs. 2323-2409. ISSN: 1573-7462. (Visitado 09-09-2024).

[17] Nikolaus Hansen, Sibylle D Müller y Petros Koumoutsakos. “Reducing the time complexity of the derandomized evolution strategy with covariance matrix adaptation (CMA-ES)”. En: *Evolutionary computation* 11.1 (2003), págs. 1-18.

[18] Nikolaus Hansen y Andreas Ostermeier. “Completely Derandomized Self-Adaptation in Evolution Strategies”. En: *Evolutionary Computation* 9.2 (jun. de 2001), págs. 159-195. (Visitado 01-09-2024).

[19] Stefano Herzel, Marco Nicolosi y Cătălin Stărică. “The cost of sustainability in optimal portfolio decisions”. En: *The European Journal of Finance* 18.3-4 (2012), págs. 333-349.

[20] Markus Hirschberger et al. “Computing the nondominated surface in tri-criterion portfolio selection”. En: *Operations Research* 61.1 (2013), págs. 169-183.

[21] John Henry Holland. *Adaptation in Natural and Artificial Systems: An Introductory Analysis with Applications to Biology, Control, and Artificial Intelligence*. en. University of Michigan Press, 1975. ISBN: 978-0-472-08460-9.

[22] Christian Igel, Nikolaus Hansen y Stefan Roth. “Covariance matrix adaptation for multi-objective optimization”. En: *Evolutionary computation* 15.1 (2007), págs. 1-28.

[23] J. Kennedy y R. Eberhart. “Particle swarm optimization”. En: *Proceedings of ICNN’95 - International Conference on Neural Networks*. Vol. 4. Nov. de 1995, 1942-1948 vol.4.

[24] Sang M Lee. “Goal programming for decision analysis of multiple objectives”. En: *Sloan Management Review* 14.2 (1973), págs. 11-24.

[25] Andrew W Lo, Constantin Petrov y Martin Wierzbicki. “It’S 11 Pm—Do You Know Where Your Liquidity Is?: The Mean–Variance–Liquidity Frontier”. En: *The world of risk management*. World Scientific, 2006, págs. 47-92.

[26] Claude Lopez, Oscar Contreras y Joseph Bendix. “ESG Ratings: The Road Ahead”. en. En: *SSRN Electronic Journal* (2020). ISSN: 1556-5068. (Visitado 26-02-2024).

[27] Wendi Lui. “The Devil is in the Details”. en. En: ().

[28] Bertrand Maillet, Sessi Tokpavi y Benoit Vaucher. “Global minimum variance portfolio optimisation under some model risk: A robust regression-based approach”. En: *European Journal of Operational Research* 244.1 (jul. de 2015), págs. 289-299. ISSN: 0377-2217.

[29] Harry M. Markowits. “Portfolio selection”. En: *Journal of finance* 7.1 (1952), págs. 71-91.

[30] Harry M Markowitz. “Mean—variance analysis”. En: *Finance* (1989), págs. 194-198.

[31] Luisa Martínez-Nieto et al. “COVID-19 impact on the Spanish stock exchange with mean-variance and diversification-based portfolios”. En: *Applied Economics Letters* 30.4 (feb. de 2023), págs. 416-422. (Visitado 24-02-2024).

[32] L’uboš Pástor, Robert F Stambaugh y Lucian A Taylor. “Sustainable investing in equilibrium”. En: *Journal of financial economics* 142.2 (2021), págs. 550-571.

[33] Riccardo Poli, James Kennedy y Tim Blackwell. “Particle Swarm Optimization: An Overview”. En: *Swarm Intelligence* 1 (oct. de 2007).

[34] Ingo Rechenberg. *Evolutionsstrategie ’94*. de. Frommann-Holzboog, 1994. ISBN: 978-3-7728-1642-0.

[35] S. Salcedo-Sanz et al. “The Coral Reefs Optimization Algorithm: A Novel Metaheuristic for Efficiently Solving Optimization Problems”. En: *The Scientific World Journal* 2014 (jul. de 2014). Publisher: Hindawi, e739768. ISSN: 2356-6140.

[36] Mei-Ping Song y Guo-Chang Gu. “Research on particle swarm optimization: a review”. En: *Proceedings of 2004 international conference on machine learning and cybernetics (IEEE Cat. No. 04EX826)*. Vol. 4. IEEE. 2004, págs. 2236-2241.

[37] J. Spronk. “Multicriteria Analysis: Operational Methods”. En: Gower Press, Farnborough, 1981. Cap. Capital Budgeting and Financial Planning with Multiple Goals.

[38] J. Spronk y G.M. Zambruno. “Geld, Banken und Versicherungen”. En: vol. Band 1. Athenum, 1981. Cap. A Multiple-Criteria Approach to Portfolio Selection, págs. 451-459.

[39] Sebastian Utz et al. “Tri-criterion inverse portfolio optimization with application to socially responsible mutual funds”. En: *European Journal of Operational Research*. 60 years following Harry Markowitz’s contribution to portfolio theory and operations research 234.2 (abr. de 2014), págs. 491-498.

[40] Sebastian Utz et al. “Tri-criterion inverse portfolio optimization with application to socially responsible mutual funds”. En: *European Journal of Operational Research* 234.2 (2014), págs. 491-498.

[41] Shanu Verma, Millie Pant y Vaclav Snasel. “A comprehensive review on NSGA-II for multi-objective combinatorial optimization problems”. En: *IEEE access* 9 (2021), págs. 57757-57791.

[42] Dongshu Wang, Dapei Tan y Lei Liu. “Particle swarm optimization algorithm: an overview”. En: *Soft computing* 22.2 (2018), págs. 387-408.

[43] Yusliza Yusoff, Mohd Salihin Ngadiman y Azlan Mohd Zain. “Overview of NSGA-II for optimizing machining process parameters”. En: *Procedia Engineering* 15 (2011), págs. 3978-3983.

Apéndice A
Manual de Instalación

Para realizar la instalación se deberá tener instalado *Python 3.12.4* o versiones superiores e instalar los siguientes paquetes:

- *deap*
- *numpy*
- *pandas*
- *cvxpy*
- *matplotlib*

Se recomienda realizar la instalación en un entorno virtual y ejecutar el siguiente comando:

```
pip install -r requirements.txt
```

De esta manera se instalarán automáticamente los paquetes anteriormente mencionados.



UNIVERSIDAD DE MÁLAGA | uma.es

E.T.S de Ingeniería Informática
Bulevar Louis Pasteur, 35
Campus de Teatinos
29071 Málaga

E.T.S. DE INGENIERÍA INFORMÁTICA